



Tecnológico de Monterrey

Calidad de Datos Adicionales

Equipo 5

Nombres y Matrículas

Ulises Orlando Carrizalez Lerín	A01027715
Mónica Monserrat Martínez Vásquez	A01710965
María José Soto Castro	A01705840
Tomás Pérez Vera	A01028008
Grant Nathaniel Keegan	A01700753
Bárbara Paola Alcántara Vega	A01799609

TC3006C.101

Inteligencia artificial avanzada para la ciencia de datos II (Gpo 501)

Índice

Tipos de Datos y Cambios Necesarios.....	3
Datos Nulos o vacíos.....	5
Rangos y Distribución de Datos.....	7
####.csv.....	7
Media de Flujos (kg/min).....	7
Sangre (ppm).....	8
Producciones (kg/min).....	9
Patadas.....	10
Incompletos.....	11
Pezones no encontrados.....	11
patadas_DDMMAA.csv.....	12

Archivo utilizado para evaluar la calidad de los datos: [dataQuality34Cows.ipynb](#)

Tipos de Datos y Cambios Necesarios

Campo	Tipo de Dato	¿Requiere cambio?
####.csv		
Acción	object	No
Producción (Kg)	object	Si (float64)
Número de ordeño	object	Si (int64)
Patada	object	No
Incompleto	object	No
Pezones no encontrados	object	No
Estado AMD *	object	Si (int64)
Media de los flujos (Kg/min) *	object	Si (float64)
Conductividad (mS / cm) *	object	Si (float64)
Sangre (ppm) *	object	Si (float64)
Destinos leche	object	No
Flujos máximos	object	Si (float64)
* Las columnas se deben de renombrar como (Ej. Sangre (ppm) DD, Sangre (ppm) DI, Sangre (ppm) TD, Sangre (ppm) TI)		

inventario_total_DDMMAA.csv		
Número del animal	int64	No
Número(s) de selección de animal	int64	No
Días en ordeño	int64	No
Edad en días	int64	No
Nº Lactación	int64	No
Número de inseminaciones	int64	No
Fecha inseminación fecundante	object	Si(datetime64)
patadas_DDMMAA.csv		
Número del animal	int64	No
DEL	int64	No
Hora inicio ordeño	object	Si(datetime64)
Ubre	int64	No
reporte_DDMMAA.csv		

Número del animal	int64	No
Nombre del grupo	object	No
Nombre(s) de selección de animal	object	No
Estado de la reproducción	object	No
Días desde la última inseminación	float64 *	Si (int64)
Días desde la última inseminación fecundante	float64 *	Si (int64)
Días Desde Último Aborto	float64 *	Si (int64)
Días desde último evento de parto	float64 *	Si (int64)
Días desde el último tratamiento de inseminación artificial temporizada	object *	Si (int64)
Días desde el último tratamiento de salud	int64	No
Días desde el último tratamiento de vacunación	object *	Si (int64)
* Los datos que son objetos o float64 y deben cambiarse a int64, requieren ser transformados al formato correspondiente. (Ej. 1,000 con el formato correcto, cambia a 1000, sin la coma)		

Datos Nulos o vacíos

En los archivos por vaca (####.csv), el único dato sin datos nulos, es Acción, debido a que siempre se registra a las vacas, como ordeñada o rechazada. El total en varias columnas de 233, resulta en la etiqueta de Acción siendo 'rechazada'. Por lo cual, no se reduce a un fallo con los datos. En los campos de 'Patada', 'Incompleto', 'Pezones no encontrados', los datos nulos resultan de la omisión de alguno de estos casos presentándose en la sesión de ordeño o por rechazo del animal.

En los archivos de inventario y patadas, no existen datos nulos.

####.csv		inventario_total_DDMMAA.csv		patadas_DDMMAA.csv		reporte_DDMMAA.csv	
Acción	0	Número del animal	0	Número del animal	0	Número del animal	0
Producción (Kg)	233	Número(s) de selección de animal	0	DEL	0	Nombre del grupo	0
Número de ordeño	233	Días en ordeño	0	Hora inicio ordeño	0	Nombre(s) de selección de animal	0
Patada	5950	Edad en días	0	Ubre	0	Estado de la reproducción	0
Incompleto	6235	Nº Lactación	0			Días desde la última inseminación	15
Pezones no encontrados	6010	Número de inseminaciones	0			Días desde la última inseminación fecundante	21
Estado AMD	233	Fecha	0			Días Desde	28

		inseminación fecundante				Último Aborto	
Media de los flujos (Kg/min)	233					Días desde último evento de parto	2
Conductividad (mS / cm)	233					Días desde el último tratamiento de inseminación artificial temporizada	15
Sangre (ppm)	233					Días desde el último tratamiento de salud	0
Destinos leche	233					Días desde el último tratamiento de vacunación	30
Flujos máximos	233						


Rangos y Distribución de Datos

Para encontrar los datos erróneos y aislados de los demás datos, sacamos los rangos de cada columna y su distribución.

####.csv

Media de Flujos (kg/min)


En los archivos individuales por animal, se encuentran rasgos distintivos entre los datos. Un ejemplo, es la lectura de Media de los flujos por ubre. En las ubres del cuadrante derecho, hay una distribución de datos menos dispersa entre 0.0 a 2.82 kg/min por cuadro. Mientras que el cuadrante izquierdo tiene un rango en ambos cuadrantes igual o mayor de 0 a 4 kg/min. Revisando más los datos, los datos arriba de 3 kg/min, resultan ser menos que los que se encuentran dentro del rango 0.0 a 2.82 kg/min.



Fuente: [dataQuality34Cows.ipynb](#)

Sangre (ppm)


En la columna de Sangre por partes en millón, la mayoría de los datos se encuentran en 0. Lo cual sería el valor esperado en una vaca saludable. Pero al retirar los valores en 0, encontramos que los rangos entre los cuadrantes derecho e izquierdo, resultan de nuevo diferentes. Los cuadros derechos teniendo un rango de en promedio [0.0, 3,338]. Mientras que los cuadros izquierdo resultan en un promedio de [0.0, 7,995].




Fuente: [dataQuality34Cows.ipynb](#)

Producciones (kg/min)

En la columna de Producciones, encontramos que los rangos más grandes, se encuentran en los cuadros traseros. Con los histogramas, podemos ver que la distribución de los datos traseros a comparación con los delanteros también es diferente. Por lo que, no se pueden descartar los datos por arriba del promedio como residuales.






Fuente: [dataQuality34Cows.ipynb](https://dataquality34cows.ipynb)

Patadas


En la columna de patadas, la cual se relaciona con la inflamación y malestar de la ubre del animal, se identifica más en el cuadro Trasero Derecho.



Fuente: dataQuality34Cows.ipynb

Incompletos


En los cuadros incompletos, los cuadros traseros también son los más comunes.



Fuente: dataQuality34Cows.ipynb

Pezones no encontrados

Los pezones menos encontrados son los cuadros traseros. Este estado, nos explica la distribución no uniforme en otras columnas.




Fuente: dataQuality34Cows.ipynb

patadas_DDMMAA.csv

DEL

Rango [0, 438]

Algunas vacas tienen más de 400 días en ordeño, lo que sugiere falta de actualización o error en el sistema en caso de que no se especifique una lactancia prolongada (2 años en vez de 1).



Fuente: dataQuality34Cows.ipynb