



Tecnológico de Monterrey

Reporte Final

Equipo 5

Nombres y Matrículas

Ulises Orlando Carrizalez Lerín	A01027715
Mónica Monserrat Martínez Vásquez	A01710965
María José Soto Castro	A01705840
Tomás Pérez Vera	A01028008
Grant Nathaniel Keegan	A01700753
Bárbara Paola Alcántara Vega	A01799609

TC3006C.101

Inteligencia artificial avanzada para la ciencia de datos II (Gpo 501)

Índice

Introducción.....	3
Resultados obtenidos.....	3
Descripción del proceso.....	3
Desviaciones del plan original.....	5
Cambio de API de OneDrive a Google Drive.....	5
Cambio de framework de modelo.....	5
Cambio de métrica de evaluación del modelo:.....	5
Reestructuración del proyecto para alinearlo con CRISP-DM.....	5
Integración tardía de logs de acceso.....	6
Cambio del objetivo de negocio.....	6
Planes de implementación.....	6
Recomendaciones a trabajo futuro.....	6
Documentación de la experiencia.....	7

Introducción

El desarrollo de este proyecto representó un esfuerzo integral que abarcó desde la comprensión del negocio ganadero hasta la implementación de una solución tecnológica funcional. A lo largo del proceso, se buscó construir una herramienta capaz de aportar valor real al CAETEC mediante la automatización de la evaluación del estado corporal y de salud de las vacas. Para lograrlo, el equipo llevó a cabo un análisis detallado de los datos disponibles, experimentó con distintos enfoques de modelado y realizó ajustes importantes al plan original con el fin de alinear el proyecto con las necesidades operativas del corral.

En las siguientes secciones se presentan los principales resultados alcanzados, una descripción detallada del proceso seguido—incluyendo las etapas y costos asociados—, las desviaciones respecto al plan inicial y sus justificaciones, así como los planes de implementación y las recomendaciones para el trabajo futuro. Este documento resume el recorrido completo del proyecto y proporciona una visión clara del estado actual del sistema y de las oportunidades de mejora que permitirán fortalecerlo en versiones posteriores.

Resultados obtenidos

Este proyecto tuvo como resultado principal el desarrollo de un sistema automatizado capaz de evaluar la condición corporal y el estado de salud de una vaca a partir de una imagen. El sistema integra información visual con los registros productivos proporcionados por el CAETEC, permitiendo identificar al animal y calcular sus días en leche. Con estos datos, y mediante el uso de la curva de lactancia como referencia fisiológica, el sistema determina si la condición corporal observada es adecuada para la etapa productiva en la que se encuentra la vaca.

Finalmente, el estado de salud se clasifica mediante un semáforo intuitivo que resume el nivel de riesgo:

- **Verde:** condición corporal óptima y sin riesgos sanitarios.
- **Amarillo:** se identifica una ligera desviación que requiere supervisión preventiva.
- **Rojo:** la vaca presenta delgadez extrema o sobrepeso significativo, lo que implica riesgo elevado y la necesidad de atención inmediata.

Este sistema constituye un avance importante hacia la implementación de herramientas de monitoreo automático y evaluación objetiva dentro del manejo ganadero.

Descripción del proceso

Para desglosar mejor el proceso y los costos se va a desglosar el proceso en etapas, descripción de ellas y cuanto costo.

Etapas	Descripción	Costo
Entendimiento del negocio	En esta etapa el equipo se familiarizó con las diferentes	Horas operativas: 62,528.75 MXN

	características del negocio lechero, lo que permitió comprender mejor el contexto operativo del cliente y asegurar que la solución desarrollada respondiera de manera más precisa a sus necesidades.	Total: 62,528.75 MXN
Entendimiento de los datos	En esta etapa el equipo se familiarizó con los datos proporcionados por el cliente, analizarlos para identificar sus capacidades y definir qué tipo de soluciones podrían generarse a partir de ellos para satisfacer los requerimientos del negocio.	Horas operativas: 35,627.82 MXN Total: 35,627.82 MXN
Preparación de los datos	En esta etapa, una vez identificado un objetivo que cumpliera con las necesidades del negocio y que fuera viable con los datos disponibles, se preparó y depuró la información con el propósito de habilitar correctamente la siguiente fase de modelado.	Horas operativas: 68,766.42 MXN Total: 68,766.42 MXN
Modelado	En esta etapa se exploraron y desarrollaron diferentes modelos que pudieran cumplir con el objetivo planteado. Para ello fue necesario rentar tarjetas gráficas y llevar a cabo entrenamientos de múltiples versiones del modelo para optimizar su rendimiento.	Horas operativas: 123,562.21 MXN Renta de GPUs: 1,000 MXN Total: 124,562.21MXN
Evaluación	En esta etapa se evaluó el desempeño del modelo para verificar si cumplía con los objetivos de negocio, así como para identificar los nuevos aportes que generaba. Esto permitió asegurar que la solución final realmente atendiera las necesidades del cliente.	Horas operativas: 102,947.55 MXN
Despliegue	En esta etapa el modelo pasó de ser únicamente código a convertirse en una aplicación	Horas operativas: 57,981.87 MXN

	web funcional, con una interfaz sencilla para el cliente. Además, se elaboró la documentación necesaria para garantizar el uso adecuado de la herramienta.	
--	--	--

Desviaciones del plan original

Durante el desarrollo del proyecto fue necesario realizar varios ajustes respecto al plan inicial. Estas desviaciones surgieron tanto por motivos técnicos como por necesidades operativas y de alineación con el objetivo de negocio. A continuación, se detallan los principales cambios realizados y su justificación:

Cambio de API de OneDrive a Google Drive

Inicialmente se había planificado utilizar la API de OneDrive para la gestión y sincronización del conjunto de datos. Sin embargo, durante las pruebas se identificaron limitaciones de acceso, inestabilidad en la autenticación y poca eficiencia en la manipulación de grandes volúmenes de imágenes. Por ello, se decidió migrar a Google Drive, cuya API resultó más estable, con mejor documentación y mayor compatibilidad con los flujos de trabajo del equipo. Esta transición permitió una gestión más ágil y confiable de los datos.

Cambio de framework de modelo

El plan original contemplaba desarrollar los modelos con TensorFlow. No obstante, se presentaron dificultades al cargar modelos pre entrenados y al adaptar el pipeline de procesamiento. PyTorch ofreció una curva de desarrollo más fluida, mayor flexibilidad y una integración más sencilla. Además, facilitó el uso de librerías relevantes para el proyecto. El cambio permitió mejorar la eficiencia del entrenamiento y reducir la complejidad del código.

Cambio de métrica de evaluación del modelo:

En etapas iniciales se había definido accuracy como métrica principal para evaluar el desempeño del modelo de predicción del BCS. Sin embargo, esta métrica no capturaba adecuadamente la naturaleza continua del BCS ni la magnitud de los errores del modelo. Por ello, se optó por utilizar el coeficiente de determinación (R^2), una métrica más apropiada para modelos de regresión que permite medir qué tan bien la predicción explica la variabilidad del valor real. Este cambio mejoró la interpretación del desempeño real del modelo.

Reestructuración del proyecto para alinearlo con CRISP-DM

El trabajo inicial se orientaba a un enfoque más lineal basado en “cascada”, lo cual dificultaba los ciclos reiterativos característicos de un proyecto de ciencia de datos. Para mejorar la sistematicidad y trazabilidad del proceso, el proyecto completo fue reestructurado siguiendo la metodología

CRISP-DM. Esto permitió una mejor organización del flujo de trabajo, revisiones más claras entre fases y una alineación más precisa entre el entendimiento del negocio, el procesamiento de datos y la construcción de modelos.

Integración tardía de logs de acceso

Aunque la incorporación de logs estaba contemplada en el diseño inicial de la aplicación, su implementación se pospuso para etapas avanzadas del proyecto debido a prioridades técnicas relacionadas con el pipeline de modelos. La integración tardía de los logs permitió habilitar el monitoreo de actividad de los usuarios y registrar interacciones clave con el sistema, lo cual es fundamental para su mantenimiento, auditoría y mejora continua.

Cambio del objetivo de negocio

El objetivo inicial se centraba únicamente en predecir el BCS de las vacas. Sin embargo, tras el análisis realizado con el CAETEC, se identificó que la verdadera necesidad operativa era evaluar el estado de salud general considerando tanto el BCS como los días en leche (DEL). Como resultado, el objetivo se amplió para incluir un análisis integral que permitiera detectar desviaciones en la curva de lactancia y generar un semáforo de salud más útil para la toma de decisiones. Este ajuste permitió que el proyecto generará un valor más directo y aplicable en la operación diaria del corral seis.

Planes de implementación

Para implementar este sistema se desarrolló una guía de despliegue al igual que un plan de entrega, a continuación se colocan las ligas a estos documentos:

Enlace a plan de entrega: [Plan de entrega](#)

Enlace a plan de monitoreo: [Plan de Monitoreo](#)

Enlace a guía de despliegue: [Guía de despliegue](#)

Documentación de experiencia

A continuación dejamos el enlace a la documentación de experiencia del equipo acerca de este reto:

Enlace a Documentación de experiencia: [Documentación de la Experiencia](#)

Recomendaciones a trabajo futuro

Con el objetivo de mejorar el desempeño, precisión y usabilidad del modelo BCS-Classifer, se proponen diversas acciones orientadas a fortalecer tanto la calidad del dataset como el flujo completo de procesamiento de imágenes. En primer lugar, entrenar el modelo con un dataset más grande permitiría obtener predicciones más robustas y generalizables. Esto implica ampliar a un volumen mayor de imágenes, ya sea mediante la instalación de cámaras en campo o a través de capturas manuales. No obstante, esta acción requiere un esfuerzo considerable en la limpieza y etiquetado de nuevos datos.

Asimismo, se recomienda replantear la metodología actual de toma de imágenes, ya que una parte significativa del dataset presenta problemas como ausencia del animal en cuadro, iluminación deficiente o baja resolución. Ajustar las condiciones de captura e incorporar diferentes posiciones de cámara enriquecería la variabilidad del dataset y contribuiría a un modelo más flexible frente a distintos entornos.

Otra acción clave es la automatización del proceso de limpieza y validación de imágenes. El desarrollo de modelos complementarios que clasifiquen, segmenten y evalúen la calidad de las imágenes de entrada permitiría que el usuario suba material sin preocuparse por filtros manuales, asegurando que solo se procesen imágenes útiles para la predicción. Aunque esta iniciativa demanda tiempo adicional y recursos computacionales, aportaría una mejora significativa en la operación del sistema.

Finalmente, para ejecutar estos avances se considera necesario contar con GPU para el entrenamiento del modelo, dado que el incremento en la cantidad de datos y la complejidad de los modelos implicará un mayor costo computacional.

En conjunto, estas recomendaciones proporcionan una ruta de mejora integral que permitirá incrementar la precisión del modelo, optimizar el flujo de datos y mejorar la experiencia de usuario en las futuras versiones de la plataforma.

Por otro lado, reemplazar la clasificación discreta de imágenes de vacas (la asignación de una etiqueta de BCS única y subjetiva) por un sistema de predicción basado en las características morfológicas del animal, da pie a un nuevo enfoque de clasificación que resalta un área de mejora del modelo actual. Puesto que este método altera la manera en que se determina la etiqueta definitiva: en lugar de etiquetar la imagen completa, se prioriza la identificación de la presencia o ausencia de características morfológicas clave (atributos), que son las que permiten al sistema concluir la etiqueta final de BCS de manera algorítmica. Un beneficio significativo de este enfoque es que la carga de etiquetado puede ser delegada a un público general sin necesidad de conocimiento profesional. Este proceso de clasificación de la tarea reduce el sesgo en las clasificaciones iniciales y facilita la creación de datasets más robustos y consistentes.