



Tecnológico de Monterrey

Reporte de evaluación

Equipo 5

Nombres y Matrículas

Ulises Orlando Carrizalez Lerín	A01027715
Mónica Monserrat Martínez Vásquez	A01710965
María José Soto Castro	A01705840
Tomás Pérez Vera	A01028008
Grant Nathaniel Keegan	A01700753
Bárbara Paola Alcántara Vega	A01799609

TC3006C.101

Inteligencia artificial avanzada para la ciencia de datos II (Gpo 501)

Índice

Introducción.....	3
Propósito de la evaluación.....	3
Modelo 1 (Separador de Vacas).....	3
Modelo 2 (YOLO-Cropper).....	3
Modelo 3 (BCS-Classifier).....	4
Health Classifier.....	4
Resultados y validación del modelo.....	4
Desempeño del modelo (Técnico).....	4
Modelo 1 (Separador de Vacas).....	4
Modelo 2 (YOLO-Cropper).....	5
Modelo 3 (BCS-Classifier).....	6
Health Classifier.....	7
Interpretación de los resultados en el contexto del negocio.....	7
Modelo 1 (Separador de Vacas).....	7
Modelo 2 (YOLO-Cropper).....	8
Modelo 3 (BCS-Classifier).....	8
Health Classifier.....	8
Comparación con la situación actual (Base de conocimiento).....	9
Evaluación según los criterios de éxito.....	9
Pipeline.....	10
Evaluación del modelo.....	10
Modelos aprobados.....	10
Modelo 1: Separador de Vacas.....	10
Modelo 2: YOLO-Cropper.....	11
Modelo 3 (BCS-Classifier).....	11
Health Classifier.....	16
Revisión del proceso.....	16
Identificación de Fallas y Pasos Engañosos.....	16
Adaptaciones y Soluciones Implementadas.....	17
Cumplimiento de Objetivos.....	17
Lecciones Aprendidas.....	17
Disponibilidad de imágenes.....	17
Restricciones de Hardware.....	17
Ajustes de Tiempo.....	18
Iteraciones Repetidas.....	18
Acciones futuras y recomendaciones.....	18
Decisión final.....	19
Conclusión.....	20
Referencias.....	20

Introducción

La fase de evaluación tiene como propósito determinar el desempeño de los modelos implementados, y verificar su grado de cumplimiento respecto a los objetivos de negocio. En este reporte, se explicaran los resultados obtenidos en diferentes rubros: El propósito de cada modelo, su rendimiento y validación, la interpretación de esos resultados, el conocimiento nuevo generado a partir de la ejecución de los modelos, su relación con los objetivos de negocio, y finalmente las lecciones aprendidas y futuras mejoras. El objetivo principal de esta fase es evaluar conocimiento nuevo con la ayuda de los modelos de aprendizaje diseñado, y como ayuda a resolver la problemática establecida durante el inicio, durante la fase de entendimiento de negocio.

Propósito de la evaluación

En esta sección se analiza qué tan bien el modelo creado cumple con los objetivos establecidos al inicio del proyecto, tanto desde el punto de vista técnico como del negocio. También se determina si el modelo puede implementarse, si requiere mejoras o si se debe replantear el proyecto.

Modelo 1 (Separador de Vacas)

Este modelo se diseñó para cumplir el criterio de minería de datos: “Las imágenes seleccionadas para entrenar el modelo presentan los atributos físicos de la vaca con aproximadamente un 80% de precisión.” Su función es filtrar todas las imágenes que no contienen una vaca, de modo que únicamente se conserven aquellas que serán útiles para análisis posteriores. Los resultados obtenidos muestran que el modelo cumple adecuadamente con el requerimiento técnico, alcanzando un accuracy de 91.84%, lo que permite reducir de manera significativa la cantidad de imágenes irrelevantes. Esto mejora la calidad del dataset y acelera el flujo de trabajo. Desde el punto de vista de negocio, el modelo es implementable, ya que automatiza un proceso que antes era manual y reduce el tiempo de limpieza de datos. Sin embargo, presenta un pequeño porcentaje de falsos negativos, los cuales muestran imágenes de vacas donde no se ven claramente.

Modelo 2 (YOLO-Cropper)

Este modelo igualmente se diseñó para cumplir el criterio de minería de datos: “Las imágenes seleccionadas para entrenar el modelo presentan los atributos físicos de la vaca con aproximadamente un 80% de precisión.” Aunque está igualmente basado en la arquitectura YOLO, su propósito es diferente al del modelo 1 ya que este busca obtener un recorte preciso que permita al clasificador final concentrarse únicamente en las características relevantes de la vaca.

El modelo alcanzó un mAP@50–95 de 80.1 %, lo que se considera aceptable para el propósito del proyecto. Este cumple con el requerimiento, ya que conserva adecuadamente la región de interés en la mayor parte de los casos. Sin embargo, aún presenta recortes imperfectos que podrían eliminar información potencialmente valiosa. Desde la perspectiva operativa, el modelo es implementable, aunque su desempeño podría mejorar si se amplía el dataset de entrenamiento o se exploran

arquitecturas más avanzadas. Para los objetivos del negocio, su precisión actual es suficiente para entrenar al modelo clasificador sin afectar drásticamente su desempeño.

Modelo 3 (BCS-Classififer)

Este modelo de clasificación se elaboró para obtener un puntaje de condición corporal (BCS) por imagen de vaca con el objetivo de cumplir los criterios : ”La diferencia entre MAE de entrenamiento y prueba debe ser ≤ 0.4 ” y “La varianza de predicciones debe estar entre 0.05 y 0.3”. Su función consiste en extraer las características correspondientes a cada puntuación de BCS para poder generar predicciones lo más cercanas a la realidad cuando se le presentan imágenes nuevas de vacas sin un puntaje definido.

Los resultados demuestran una varianza de 0.232, la cual se encuentra entre 0.05 y 0.3 tal y como se describe en el objetivo de minería de datos, además, se obtuvo una R^2 de 0.7226 en prueba, mostrando que el modelo generaliza y explica la variabilidad en los valores reales de BCS, además de contar con un MAE de entrenamiento de 0.0728 y uno de prueba de 0.3352 con una diferencia entre ambos de 0.2624, alcanzando el objetivo de contar con una diferencia entre MAE de entrenamiento y prueba de ≤ 0.4 .

Health Classifier

Este es el modelo central del proyecto y el que cumple la mayoría de los criterios de minería de datos, así como el principal criterio de negocio: “Determinar el estado de salud y condición corporal de vacas lecheras del corral seis del CAETEC.”

El modelo con su pipeline implementada, logró una precisión cercana al 89 %, lo cual demuestra que puede realizar predicciones fiables del estado de salud de la vaca a partir de las imágenes procesadas por el modelo. Con estos resultados, el modelo cumple de manera satisfactoria tanto los requerimientos técnicos como los de negocio, ya que proporciona información consistente y útil para el monitoreo del ganado. Sin embargo, el tamaño considerable de la arquitectura utilizada (ConvNeXt-Base) implica un costo computacional elevado, por lo que se recomienda optimizar el sistema para ejecución en GPU pero es suficiente para cumplir con los requerimientos del proyecto.

Resultados y validación del modelo

Desempeño del modelo (Técnico)

En esta sección se describen las métricas principales obtenidas (ej. Accuracy, MAE, F1 Score, etc.) de cada modelo. Y se interpreta qué significan estas métricas en el contexto del modelo.

Modelo 1 (Separador de Vacas)

La métrica accuracy se seleccionó para evaluar el desempeño del modelo debido a que permite medir de manera directa y comprensible la proporción de decisiones correctas al clasificar imágenes como “con vaca” o “sin vaca”. Esta métrica resulta especialmente adecuada en esta etapa del sistema, ya que


el objetivo principal es garantizar que el modelo identifica correctamente las imágenes que contienen una vaca, minimizando el riesgo de incluir en el entrenamiento imágenes que no son relevantes.

Para validar el accuracy del modelo, se validó manual las imágenes y los resultados del modelo, asegurando que la separación entre “con vaca” y “sin vaca” fuera correcta y corrigiendo los errores detectados. Esto permitió establecer una referencia confiable para medir con precisión el rendimiento real del sistema. Las pruebas se ejecutaron utilizando los parámetros de inferencia predeterminados (IoU = 0.4, conf = 0.1).

Durante la evaluación, el modelo clasificó 37,842 imágenes como “sin vaca”, dentro de las cuales se identificaron 822 falsos negativos, es decir, casos donde la imagen sí contenía una vaca pero fue descartada por el modelo. En consecuencia, el sistema logró detectar correctamente 9,213 de las 10,035 imágenes que realmente contenían una vaca. A partir de estos resultados, se obtuvo un accuracy de 91.84 %, lo que confirma que el modelo presenta un desempeño sólido en la tarea de detección de vacas.

¿Por qué el modelo no detectó 822 de las vacas?

Algo importante para notar, es que las imágenes que fueron detectadas como falsos negativos, son imágenes que son difíciles de contar como una vaca por un modelo de aprendizaje de máquina. Esto es debido a condiciones de luz, la vaca tomando demasiado espacio, o solo mostrando una diminuta parte de la vaca como la cabeza o las piernas. Esto hace difícil la detección a menos que se tenga el contexto de que dichas partes o fotografías imperfectas pertenecen a una vaca. Por esto, se puede concluir que el nivel de accuracy del separador de vacas es bastante bueno. A continuación, se mostrarán varios ejemplos de dichas imágenes.

Imagen Mostrando un pequeño pedazo de las piernas de la vaca 	Imagen mostrando un pequeño pedazo de la cabeza de la vaca 	Imagen con condiciones de luz brillosas y posición cerca de la cámara 	Imagen demasiado borrosa y con suciedad 
Imagen con la vaca cubriendo toda la cámara 	Imagen con la vaca en una posición que no muestra rasgos identificables de vacas 	Imagen donde la vaca pasa demasiado rápido y la imagen sale borrosa 	

Modelo 2 (YOLO-Cropper)

Para evaluar el desempeño del modelo se empleó la métrica mAP (mean Average Precision), la cual es ampliamente utilizada en tareas de detección de objetos debido a que mide simultáneamente la precisión y la capacidad del modelo para localizar correctamente las regiones de interés. En particular, se utilizó el indicador mAP@50–95 (B), que corresponde al promedio de precisión evaluado sobre múltiples umbrales de Intersection over Union (IoU), desde 0.50 hasta 0.95 en incrementos de 0.05. Este tipo de métrica es especialmente exigente, ya que requiere que las detecciones mantengan tanto la ubicación como el tamaño del recorte con un alto nivel de exactitud.

El modelo obtuvo un mAP@50–95 de 80.1%, lo cual se considera un resultado sólido y adecuado para los objetivos del sistema. Este nivel de desempeño indica que el modelo logra detectar consistentemente a las vacas dentro de las imágenes y delimitar adecuadamente la zona que posteriormente será utilizada por el clasificador de condición corporal (BCS). A continuación los resultados:

Entrada	Resultado
	

Modelo 3 (BCS-Classifier)

Para la evaluación del modelo de clasificación por puntuación de condición corporal (BCS) se empleó principalmente R^2 , al ser una medida que representa la varianza explicada, la magnitud del error promedio y penaliza errores grandes. Sin embargo, el resto de métricas como MSE, MAE, Bias y Varianza nos permiten evaluar a mayor detalle el modelo.

Métricas de ConvNeXt-Base	
Resultados de validación	Resultados de prueba
MAE = 0.2893 MSE = 0.2264 Bias = 0.0254 Varianza = 0.232 R2 = 0.7676	MAE = 0.3352 MSE = 0.2745 Bias = -0.0548 R2 = 0.7226

El modelo ConvNext permitió alcanzar las métricas objetivo:

- Mean Absolute Error (MAE) ≤ 0.4

- Mean Squared Error (MSE)
- Bias ± 0.5 de BCS
- Varianza donde $0.05 < \text{predicción} < 0.3$
- R^2 (Coeficiente de determinación) $> 70\%$

Al contar con un valor de MAE (validación) de 0.2893 y MAE (Prueba) de 0.3352, muestra que, en promedio, el modelo se equivoca menos de 0.34 puntos en la escala de BCS (1–5). Mientras que el valor de MSE (validación) de 0.2264 y MSE (prueba) de 0.2745 indican que el modelo rara vez comete errores grandes, lo que significa que el modelo no falla drásticamente en vacas muy delgadas o muy gordas. Mientras que ambos valores de Bias se encuentran dentro del rango esperado de ± 0.5 BCS, aunque en validación, tiende a predecir ligeramente más alto (+0.02) y en prueba, tiende a predecir ligeramente más bajo (-0.05).

La varianza del error, cuenta con un valor de validación de 0.232, lo que confirma que el modelo no comete errores muy distintos entre vacas y la predicción es estable en vez de errática.

Por último, contamos con valores de R^2 de validación en 0.7676 y en prueba de 0.7226, refiriendo a un 77% de la variabilidad del BCS en validación y 72% en prueba, por lo que podemos concluir para este modelo que ConvNeXt predice la condición corporal de las vacas con una precisión muy similar a la de un evaluador humano consistente, cometiendo en promedio menos de ± 0.35 puntos de error, siendo estable, sin sesgos y explicando más del 70% de la variabilidad real.

Health Classifier

Para evaluar el desempeño del modelo en el pipeline completo, se decidió utilizar la métrica de certeza (accuracy), debido a la naturaleza del problema y al tipo de salida que genera el sistema. En este caso, el modelo produce finalmente tres clases discretas correspondientes al semáforo de salud de la vaca: verde, amarillo y rojo. Estas clases representan categorías mutuamente excluyentes que describen el estado corporal estimado en relación con su rango saludable de BCS.

El uso de accuracy es apropiado porque esta métrica mide la proporción de predicciones correctas respecto al total de casos evaluados y, por lo tanto, ofrece una forma directa y fácilmente interpretable de determinar qué tan bien el modelo asigna cada vaca a la clase adecuada. En otras palabras, permite cuantificar en qué porcentaje de ocasiones el sistema coincide con la clasificación real basada en el BCS verdadero de la vaca.

Interpretación de los resultados en el contexto del negocio

A continuación se describe si el modelo ayuda al equipo a tomar mejores decisiones. Se listan los problemas que resuelve, y se validan con los objetivos de negocio. Es decir, si ayuda a evaluar la salud de las vacas.

Modelo 1 (Separador de Vacas)

El modelo basado en YOLOv8m automatiza una tarea de identificar si una imagen contiene una vaca. Esto no solo agiliza el flujo de trabajo, sino que también mejora la eficiencia del proceso, ya que una parte significativa de las imágenes capturadas no incluye ningún animal. Estas imágenes irrelevantes

generan ruido, aumentan el volumen del dataset y perjudican el desempeño de modelos posteriores encargados de clasificar el BCS. Las imágenes detectadas y válidas se envían automáticamente a una carpeta de análisis, mientras las que no cuentan con una vaca son descartadas. En consecuencia, el modelo cumple con los objetivos planteados en la etapa de minería de datos, al incrementar la calidad del dataset y reducir significativamente el tiempo dedicado al filtrado manual.

Modelo 2 (YOLO-Cropper)

Este modelo es fundamental en el procesamiento previo al modelo MuuMetrics, ya que, como se observa en el dataset, las vacas pueden encontrarse en diferentes posiciones dentro de las imágenes y no ocupan todo el encuadre. Esto genera un alto nivel de ruido por el fondo que puede afectar significativamente la identificación de características relevantes.

El modelo soluciona este problema al recortar las imágenes, de manera que solo se conserven las partes de interés de la vaca. Así, el modelo MuuMetrics puede concentrarse en esas regiones para identificar las características que le permiten evaluar correctamente al animal, lo que se traduce en mejores predicciones. Si bien este modelo no cumple directamente un objetivo de negocio, contribuye de manera importante a su logro al mejorar la calidad de los datos utilizados para entrenar el BCS-Classififer, complementando el modelo separador de vacas para eficientar el filtrado y la calidad de los datos.

Modelo 3 (BCS-Classififer)

Como se mostró en los resultados y validación del modelo ConvNeXt predice la condición corporal de las vacas con una precisión muy similar a la de un evaluador humano consistente, lo que permite que un sistema sea instalado en un corral del establo del socio formador para obtener las puntuaciones de cada vaca en cuestión de minutos y que el ingeniero a cargo pueda tomar las decisiones pertinentes sin necesidad de entrar al corral clasificando y registrando puntajes de condición corporal a mano cada semana.

La facilidad de clasificación es un incentivo para el personal de un establo en términos de constancia, ya que muchas veces debido a cuestiones de tiempo o acontecimientos en los establos, la clasificación de la condición corporal de las vacas se encuentra post puesta para atender otras tareas debido a la naturaleza impredecible de un establo lechero.

Este modelo acelera la calificación de condición corporal para incorporarse a Health-Classififer y cumplir con el objetivo de negocios al incorporar los días en leche que presentan una imagen más completa con respecto a la salud del hato lechero con la curva de lactancia.

Health Classifier

Actualmente, en la industria lechera, la evaluación del estado corporal de las vacas depende de un experto que analiza sus características físicas. Sin embargo, este experto no siempre está disponible y, además, los resultados pueden variar significativamente entre evaluadores. Este modelo atiende dicha

necesidad de manera eficiente, consistente y operativa las 24 horas del día. De esta forma, el veterinario o responsable en turno puede tener la certeza de que existe un sistema que monitorea continuamente la condición corporal de las vacas y que, ante cualquier discrepancia en su estado, emitirá una alerta temprana para permitir una intervención oportuna antes de que la situación empeore.

El objetivo de negocio establecido en el plan de proyecto — “Determinar el estado de salud y condición corporal de vacas lecheras del corral seis del CAETEC” — se considera cumplido, ya que el modelo es capaz de predecir el estado de salud de las vacas con un 89% de exactitud una vez incorporado en el pipeline. Esto permite automatizar la vigilancia del hato, reducir la dependencia de evaluaciones subjetivas, mejorar la capacidad de respuesta ante problemas de salud y, en última instancia, contribuir a la mejora del bienestar animal y de la productividad del sistema.

Comparación con la situación actual (Base de conocimiento)

Los resultados obtenidos en este proyecto sí aportan elementos novedosos respecto a la situación actual en la industria ganadera. Tradicionalmente, la evaluación del estado corporal de las vacas depende de la observación manual realizada por expertos, un proceso subjetivo, variable entre evaluadores, poco escalable y difícil de mantener de forma continua. En contraste, el sistema desarrollado introduce un enfoque capaz de operar de manera constante, objetiva y eficiente, reduciendo de manera significativa la carga operativa y mejorando la capacidad de monitoreo del hato. Este sistema constituye un aporte nuevo, tanto en términos de proceso como de valor práctico, al reemplazar una tarea altamente dependiente del criterio humano por un pipeline de visión computacional replicable y escalable.

Al inicio de este proyecto se planteó como conocimiento a generar, que era posible estimar el Body Condition Score (BCS) de una vaca mediante imágenes utilizando modelos de visión computacional; arquitecturas de aprendizaje profundo; y realizar diagnósticos de salud con base en las características extraídas con base en el uso de dichas arquitecturas. El proyecto validó esta premisa al lograr predecir el estado de salud de las vacas con un 89 % de exactitud haciendo uso de las métricas de días en leche por cada vaca, en conjunto de la estimación automática del BCS. Estos resultados, obtenidos con datos reales del CAETEC, refuerzan la evidencia de que los modelos de aprendizaje profundo pueden igualar o incluso superar la consistencia del análisis humano, especialmente cuando se integran en un pipeline estructurado.

Evaluación según los criterios de éxito

Aquí se describen los criterios de éxito del objetivo de negocio, el resultado obtenido y si cumple o no. También una evidencia de porque decimos que si cumple. Para evaluar el cumplimiento de este modelo respecto al criterio de éxito — “ $\geq 80\%$ de las predicciones de salud deben coincidir con la valoración real.” — , fue necesario implementar una pipeline que procesa los resultados del modelo y genera el semáforo de salud de la vaca esperado por el usuario. A continuación, se explica su funcionamiento.

Pipeline

Tal como se mencionó en el documento Data Understanding, para evaluar la salud de la vaca se requiere conocer cuántos días en leche llevaba al momento en que se tomó la fotografía. Para ello, se utilizó el script calculoDELvacas.py. Este código utiliza la fecha en que fue tomada la foto y, mediante los registros de ordeña individual, identifica el ID de la vaca. Posteriormente, se consultan los registros de DEL en el archivo patadas.csv y, a través de la diferencia entre la fecha del registro y la fecha de la imagen, se determina el número de DEL correspondiente. Este proceso se describe con mayor detalle en el documento Reporte de preparación de datos. [Reporte de preparación de datos](#)

Una vez obtenidos los DEL, se calcula el rango de BCS saludable para la vaca con base en su curva de lactancia. Aunque la ecuación exacta no se encontraba explícita en el artículo de referencia, se replicó la ecuación que aproxima este comportamiento para calcular el valor máximo del rango:

$$BCS(x) = -1.63170163 \times 10^{-10} x^4 + 6.92566693 \times 10^{-8} x^3 + 1.94599845 \times 10^{-5} x^2 - 8.59893810 \times 10^{-3} x + 3.06663559$$

Mediante el uso de puntos clave de referencia:

Python

```
x_key = np.array([0, 50, 100, 150, 200, 250, 300, 350, 400])
y_key = np.array([3.10, 2.85, 2.55, 2.25, 2.55, 2.75, 2.85, 2.95, 3.10]) - 0.07
```

Este resultado se discretiza redondeando el resultado de esta ecuación al cuartil más cercano. Para obtener el valor mínimo, simplemente se restó 0.5 puntos de BCS, ya que la diferencia estándar entre ambos valores es precisamente de 0.5. Con el rango de salud definido, es posible evaluar el estado de la vaca. Se planteó un sistema de semáforo:

- **Verde:** la vaca está dentro del rango saludable.
- **Amarillo:** la vaca está ligeramente fuera del rango (± 0.25 puntos de BCS respecto al límite).
- **Rojo:** la vaca está fuera del rango por más de 0.25 puntos, lo cual indica que requiere atención inmediata.

Para asignar estos valores, se implementó una función que compara la predicción del modelo con el rango saludable y determina el color correspondiente.




Figura 1. (A) Curva definida por ecuación y puntos de referencia (B) Curva con los colores del semáforo asignados.

Evaluación del modelo

Para verificar que el modelo cumpliera con el requerimiento de negocio, se realizó una prueba con 599 predicciones. Para cada una, se calcularon los semáforos correspondientes y se compararon con los semáforos obtenidos a partir del BCS real de la vaca. Dado que el resultado final consiste en tres clases (verde, amarillo y rojo), se decidió evaluar el desempeño mediante la métrica accuracy. El modelo obtuvo un 89.46% de accuracy, lo cual se considera un resultado satisfactorio que permite concluir que el requerimiento de negocio fue cumplido.

Modelos aprobados

Modelo 1: Separador de Vacas

Entre las alternativas consideradas para la tarea de detección de vacas se evaluaron arquitecturas como [DETR](#) y [Faster-CNN](#), ambas reconocidas por su precisión en tareas de detección de objetos. Sin embargo, se optó por YOLOv8m debido a su mayor simplicidad operativa, rapidez de inferencia y facilidad de implementación. Además, el equipo contaba con experiencia previa en modelos de la familia YOLO y en el ecosistema de Ultralytics, lo cual disminuye significativamente la complejidad de integración, gracias a su API estable en Python que permitió incorporar el modelo directamente en el script LimpiarVacas.py. La variante "m" (medium) fue seleccionada específicamente porque ofrece un equilibrio adecuado entre costo computacional y desempeño, lo que la convierte en una opción eficiente para procesar miles de imágenes.

Sin embargo, YOLOv8m presenta ciertas limitaciones. Aunque su precisión general fue elevada, se identificaron algunos falsos negativos, es decir, imágenes que contenían vacas pero fueron clasificadas como irrelevantes. Su rendimiento disminuye cuando se procesa un volumen muy grande de datos sin una GPU, lo que puede alargar los tiempos de procesamiento. Por último, al tratarse de un modelo preentrenado y con capacidad limitada para exponer información interna del proceso de aprendizaje, se comporta como una caja negra, ofreciendo predicciones altamente efectivas pero con poca interpretabilidad.

Modelo 2: YOLO-Cropper

Para el segundo modelo, responsable de generar bounding boxes que permiten recortar regiones relevantes antes de alimentar el modelo clasificador BCS, se requería una arquitectura más robusta y con mayor precisión que la utilizada en el separador de vacas. La tarea de recorte es crítica, ya que determina qué información visual estará disponible para el modelo de clasificación posterior. Por ello, se eligió una variante más grande y pesada de YOLOv8, capaz de capturar mejor regiones específicas del cuerpo de la vaca.

Aun así, este modelo comparte varias de las limitaciones del primero. Durante la validación, presentó una precisión aproximada de 80.1% en la generación de bounding boxes, lo que implica que en ciertos casos podría recortar demasiado o insuficientemente las zonas de interés. Esto es relevante porque un recorte incorrecto puede eliminar características visuales útiles para el entrenamiento del

BCS-Classfier, afectando su futura capacidad de generalización. Además, debido a su mayor tamaño, este modelo requiere de forma aún más estricta una GPU para operar con tiempos razonables. Finalmente, al igual que el modelo previo, también funciona como una caja negra, ya que no es posible conocer con detalle qué patrones aprende o qué criterios específicos utiliza para generar los recortes.

Modelo 3 (BCS-Classfier)

Para este modelo se evaluaron diversas arquitecturas de redes neuronales convolucionales, incluyendo VGG y EfficientNet. Sin embargo, estas alternativas presentaron limitaciones relevantes durante la fase de modelado, como un alto número de parámetros sin ofrecer mejoras significativas, también varios presentaron dificultades durante el proceso de carga y adaptación, además de no alinearse completamente con los criterios de minería de datos del proyecto.

Finalmente, se seleccionó la arquitectura ConvNeXt-Base, esta arquitectura ofrece mejoras en estabilidad, normalización y capacidad para capturar patrones espaciales más finos, lo que la convierte en una excelente candidata para tareas de clasificación basadas en detalles anatómicos sutiles. ConvNeXt-Base suele proporcionar mayor precisión en comparación con arquitecturas clásicas, manteniendo una implementación relativamente sencilla gracias a su compatibilidad con PyTorch lo que facilitó el cargado de este modelo. Finalmente la característica que más beneficio es que este modelo trabaja muy bien con datasets pequeños, lo que nos permitió entrenar un modelo de buena calidad sin importar que contábamos con un dataset bastante reducido.

Tras realizar gráficos de evaluación del modelo crudo de clasificación antes de incorporarse al pipeline se puede observar el desempeño a mayor detalle:




Figura 2. Distribución de valores reales contra predicciones, donde la línea punteada roja muestra el caso ideal de predicción (verdadero).

El gráfico de verdadero vs predicción nos muestra que el modelo captura la tendencia bien, y considerando el valor de R^2 de 0.768 en el entrenamiento, se sabe que el modelo explica el 76.8% de

la variabilidad en los valores reales de BCS para los datos de entrenamiento en el gráfico, lo cual es un resultado sólido para una evaluación biológica subjetiva como lo es la condición corporal para vacas de un hato lechero de raza Holstein.

El patrón de distribución indica que animales con puntajes bajos (2.0-3.0) cuentan con predicciones cercanas a la realidad, mientras que animales con puntajes más altos (4.0-5.0) muestran un poco más de ruido, lo que significa que el modelo muestra dificultades diferenciando diferencias sutiles mientras más alto sea el puntaje con el que cuenta el individuo. Esto tiene sentido, ya que la menor cantidad de imágenes se encuentra en la carpeta que guarda las calificaciones de 5.




Figura 3. Comparación gráfica de los valores residuales entre los valores predichos, donde la línea punteada roja se encuentra en el cero, significando una ausencia de bias sistemático.

Idealmente esta gráfica debería mostrar ruido aleatorio alrededor de la línea cero sin un patrón aparente, sin embargo, aunque casi todos los puntos están cerca de la línea cero sin un bias sistemático aparente, se puede observar que la mayoría de las predicciones bajas se encuentran en valores de >4.5 , mientras que, la mayoría de las predicciones altas se encuentran en rango medio 3.25-3.75.

Al no haber una distribución en “forma de U”, se muestra que los errores no están expandiéndose para ninguno de las clasificaciones de BCS, además de contar con una buena homocedasticidad (varianza del error constante).




Figura 4. Histogramas superpuestos de la distribución real y la distribución de predicciones realizadas.

Las dos distribuciones (predicción en naranja y valor real en azul), se encuentran ampliamente alineadas, contando con picos en valores entre 3 y 4.5-4.75, lo que significa que el modelo aprendió la forma global de la distribución para la puntuación de BCS de forma correcta, sin embargo, las predicciones para 4.5-5.0 se encuentran ligeramente comprimidas hacia abajo, mostrando que el modelo tiende a subestimar altos puntajes de BCS. Lo mismo sucede con valores predichos de 2.25-2.75, aunque muestran menos predicciones subestimadas.

El modelo rara vez predice valores muy bajos (<2.2) o muy altos (>4.8) en comparación con los valores reales. Esto es común en los modelos de regresión cuando los datos de entrenamiento en los extremos son escasos, lo cual es el caso más probable, o el modelo está regularizado y la función de pérdida penaliza más las desviaciones extremas.




Figura 5. Histograma con la distribución de errores de predicción.

La distribución del error se encuentra concentrada alrededor de 0, demostrando que no existe un bias global (que el modelo no sobreestima o subestima sistemáticamente a través del todo dataset). La mayoría de los errores se concentran entre -0.4 y +0.3 –aproximadamente dentro del ± 0.35 BCS, lo cual es aceptable cuando se teclera un problema donde la variación del anotador/etiquetador humano es de un ± 0.25 o mayor (Mullins et al, 2019).

Sin embargo, sí existen valores extremos o outliers, donde hay grandes sobre predicciones y sub predicciones (-1.0 y 1.0 o 2.0), las cuales pueden ocurrir debido a una clasificación de BCS incorrecta, la mala calidad de la imagen (sombra, ángulo, postura de la vaca) y/o problemas de segmentación (la grupa, las costillas y/o los huesos de la cadera no se extrajeron correctamente).


Además, la ligera desviación a la izquierda del gráfico, confirma que animales con puntuaciones altas de BCS tienden a tener valores predichos ligeramente más bajos que los reales, creando errores de valor negativo. Estos pocos valores sobresalientes/outliers sugieren posibles problemas de anotación/etiquetado, ruido, o calidad de la imagen.

El modelo es confiable y consistente para calificaciones bajas a intermedias, mientras que existe un área de oportunidad para refinar el entrenamiento con una base de datos que cuente con más imágenes de animales calificados en 5 y otras puntuaciones donde la cantidad de imágenes es baja, como 3.25, 3.5, 3.75, y 4.

Además con respecto a la gráfica de residuales vs predicciones, se demuestra que el modelo no muestra errores sistemáticos mayores pero sí puede ser ligeramente conservador para valores más altos de BCS, prediciendo valores menores al real.

No obstante, el modelo presenta una limitación importante: su tamaño final excede los 300 MB, lo cual incrementa considerablemente el tiempo de inferencia cuando se ejecuta sin soporte de GPU. Esto vuelve el proceso de generación de predicciones más lento y demanda recursos de hardware más robustos, especialmente cuando se requiere procesar grandes volúmenes de imágenes.

MuuMetrics Health Classifier



El **MuuMetrics Health Classifier** es un sistema que integra el BCS-Classifer con información productiva y de comportamiento para estimar el estado de salud de cada vaca. A partir de dos archivos .csv ,uno con el historial individual, y otro con registros de patadas durante la ordeña, el sistema genera un DataFrame consolidado donde calcula automáticamente los días en leche (DEL). Cuando recibe una imagen .jpg, extrae fecha de ordeño y con base en esta recupera los DEL y ID, esto lo vincula con la predicción del BCS-Classifer y combina todas las métricas disponibles dentro del contexto fisiológico de la curva de lactancia.

Con esta integración, el sistema identifica patrones anómalos en pérdida o ganancia de condición corporal. En pruebas internas, el MuuMetrics Health Classifier alcanzó una accuracy del 90% en su prueba de pronóstico temprano del estado de salud, cumpliendo con los criterios de éxito del objetivo

de negocio al permitir una detección anticipada de problemas metabólicos o de bienestar que afectan la productividad del hato.

Revisión del proceso

Identificación de Fallas y Pasos Engañosos

Durante el desarrollo del proyecto se identificaron fallas críticas en etapas iniciales, principalmente relacionadas con la calidad de los datos. Se detectó un etiquetado incorrecto del BCS en algunas vacas –visto con mayor claridad en la **Figura 3**–, selección inadecuada de imágenes que no mostraban claramente los rasgos físicos necesarios, y recortes deficientes en las áreas de interés. Estas fallas impactaron directamente la capacidad de los primeros modelos para generalizar adecuadamente.

Un paso engañoso significativo fue la elección inicial de métricas inapropiadas para la evaluación del modelo. La utilización de accuracy como métrica principal no es significativa en un modelo de regresión, ya que las salidas de la regresión son continuas, no discretas, e ignora qué tan cercanas se encuentran las predicciones al valor real, por lo que en realidad el problema requería el uso de coeficiente de determinación (R^2) al medir la varianza explicada, la magnitud del error promedio y penalizar errores grandes. Esta mala elección de métrica en un inicio, llevó al equipo a considerar la inyección de datos como medida para incrementar el valor de la métrica de accuracy cuando la métrica correcta para una regresión es coeficiente de determinación, resultando en iteraciones y consumo de recursos adicionales en la fase de modelado.

Adaptaciones y Soluciones Implementadas

El proceso requirió adaptaciones significativas, incluyendo la migración del framework de TensorFlow a PyTorch debido a problemas de compatibilidad entre diferentes computadoras y versiones de CUDA. Además, la contratación de servicios de GPU en la nube se utilizó para compensar la falta de capacidad local de procesamiento. Estas acciones alternativas, aunque no planificadas inicialmente, permitieron continuar con el desarrollo de manera eficiente.

Cumplimiento de Objetivos

Pese a los desafíos encontrados, el modelo final basado en ConvNeXt-Base cumplió satisfactoriamente con todos los criterios de éxito establecidos. Las métricas obtenidas (MAE validación: 0.2893, MAE prueba: 0.3352, R^2 : 0.7226-0.7676) se mantuvieron dentro de los rangos requeridos, demostrando una diferencia de MAE entre entrenamiento y prueba de 0.0459 (≤ 0.4 exigido) y un bias dentro del rango ± 0.5 . La integración con los datos tabulares de días en leche permitió alcanzar un 89% de precisión en la determinación del estado de salud, superando el criterio de éxito del negocio del 80%.

Lecciones Aprendidas

El proyecto demostró la importancia de una distribución clara de tareas según las competencias del equipo y la definición precisa de objetivos desde el inicio. Las principales dificultades incluyeron:

Disponibilidad de imágenes

A pesar de que el socio formador puso a disponibilidad como recursos una serie de 57,870 imágenes, dado el enfoque del presente trabajo, únicamente 508 de las imágenes provistas resultaron efectivas para el entrenamiento del modelo para realizar la estimación automática de la condición corporal (Body Condition Score, BCS). Por lo que es importante que el sistema de recolección de datos esté optimizado para obtener más imágenes objetivo sobre imágenes ruido o en su defecto, considerar una mayor ventana de tiempo para que las técnicas de limpieza no reduzcan demasiado la cantidad de imágenes.

Restricciones de Hardware

Dado el enfoque del propio proyecto, una limitante que se presentó, fue el no contar con el hardware necesario para poder realizar los entrenamientos del modelo en tiempo óptimo, lo que implicó destinar una cantidad considerable de tiempo y recursos entre cada iteración del modelo para experimentar con diferentes arquitecturas que pudieran generar el nivel de abstracción necesario para cumplir con las métricas que conforman los criterios de éxito del objetivo de minería de datos. De no ser por la investigación de avances recientes en el desarrollo y mejora de arquitecturas (inclinando el proyecto al empleo de ConvNext como una gran mejora de ResNet-50 cuando se trabaja con muy pocas imágenes), mayor poder computacional podría haberse requerido.

Ajustes de Tiempo

Una de las principales dificultades presentadas durante el desarrollo del proyecto, fue el hecho de contar con lapsos de tiempos ajustados entre cada iteración de la metodología, ello con base en la cantidad de actividades y entregables que conforman cada una de estas. Subestimando incluso los tiempos necesarios para los ajustes del modelo.

Iteraciones Repetidas

Dada la naturaleza de la metodología CRISP-DM, una dificultad presentada en el desarrollo del proyecto, fue realizar una serie de iteraciones sobre una misma fase de la metodología, para poder continuar con la fase subsecuente.

Como mejora para futuros proyectos, se recomienda realizar un análisis más exhaustivo de las métricas apropiadas desde la fase inicial, con el objetivo de evitar un exceso de iteraciones e incrementar la eficiencia en el uso de tiempos. La experiencia validó que, pese a las suposiciones iniciales sobre la dificultad de automatizar la estimación del BCS, el estándar de calificación de

condición corporal Elanco, permitió desarrollar una solución efectiva que cumple con los requerimientos técnicos y de negocio establecidos.

Acciones futuras y recomendaciones

Los objetivos del proyecto de MuuMetrics se cumplieron exitosamente. Sin embargo hay áreas de mejora para expandir o agregar valor al proyecto. Para estas acciones o recomendaciones, se consideran las ventajas y desventajas de cada una. A continuación, se plantean estas ideas discutidas previamente por el equipo, y lo requerido para cada acción.

Acción propuesta	Beneficios	Desventajas	Recursos necesarios	Recomendación
Entrenar el modelo de BCS-Classfier con un dataset más grande	Mejores predicciones y mayor robustez.	Se requiere de más tiempo para limpiar y etiquetar más información.	• Instalar camaras/tomar imágenes similares a mano en su defecto • Actualizar los .csv proporcionados para la nueva información	Replantear la manera en que se toman las imágenes, ya que la manera actual presenta muchas imágenes sin características relevantes (no tienen vacas presentes, las imágenes pueden estar muy oscuras, la calidad es muy baja, etc.). Enriquecer los datos con diferentes posiciones de la cámara para permitir mayor dinamismo y flexibilidad en el modelo.
Automatización de limpieza de datos	El usuario va a poder subir imágenes sin la necesidad de preocuparse de que las imágenes cuentan con las características y calidad necesarias para hacer las predicciones	Se requiere de tiempo para generar modelos adicionales que se encarguen de clasificar, segmentar y evaluar las imágenes de entrada además de incorporarlos con el material ya presente.	• GPU para entrenar el modelo • Tiempo para generar el modelo	N.A.

Decisión final

Con base en los resultados obtenidos, se considera viable implementar el sistema integrado de Health Classifier en una fase piloto, ya que cumple tanto con el objetivo de negocio como con los criterios establecidos en el proceso de minería de datos, al incluir en su pipeline el modelo BCS-classifier. No obstante, al no haber sido probado en condiciones reales de operación, se considera pertinente desplegar el modelo inicialmente bajo supervisión, monitoreando su desempeño en el entorno en el que se plantea su trabajo.

Conclusión

La evaluación integral de los tres modelos desarrollados demuestra que el sistema propuesto es técnicamente sólido y viable para una implementación gradual dentro del entorno operativo del CAETEC. El modelo de evaluación de Body Condition Score (BCS-Classifer) aporta valor específico al flujo de procesamiento y, en conjunto, cumplen con los objetivos de minería de datos definidos al inicio del proyecto. No obstante, como se mencionó previamente fue necesario diseñar un pipeline completo que integrará las diferentes extracciones de datos y permitiera devolver una evaluación final del estado de salud de la vaca (Health Classifier).

Los resultados obtenidos evidencian que el sistema supera las limitaciones del método manual tradicional, al ofrecer mayor consistencia, escalabilidad y rapidez en el análisis del estado corporal del ganado. Aunque aún existen áreas de mejora (especialmente en la robustez del recorte de atributos y en la reducción de falsos negativos) el desempeño alcanzado por el sistema es lo suficientemente alto como para justificar su avance hacia una fase piloto supervisada.

En conjunto, el proyecto no solo confirma la aplicabilidad de técnicas modernas de visión por computadora en el sector ganadero, sino que también demuestra que su integración en un pipeline modular puede mejorar significativamente la calidad de los datos procesados y fortalecer la toma de decisiones operativas. Con los ajustes y validaciones adicionales en un entorno real, este sistema tiene el potencial de convertirse en una herramienta esencial para el monitoreo continuo y la gestión proactiva de la salud del hato lechero.

Referencias

Elanco Animal Health (1997). Body condition scoring in dairy cattle (pag 49-52).

[https://www.vet.cornell.edu/sites/default/files/1e_Elanco%20Cow%20Body condition scoring_V3.pdf](https://www.vet.cornell.edu/sites/default/files/1e_Elanco%20Cow%20Body%20condition%20scoring_V3.pdf)

Mullins, I. L., Truman, C. M., Campler, M., Boden, L. A., Reader, T., & Tucker, C. B. (2019).

Validation of a commercial automated body condition scoring system on a commercial dairy farm. Animals, 9(6), 287. <https://doi.org/10.3390/ani9060287>

Viquez, S. (2023, July 19). *Tutorial: Monitoring an ML Model with NannyML and Google Colab.*

<https://www.nannyml.com/blog/tutorial-monitoring-ml-model-with-nannyml-google-colab>