



Tecnológico de Monterrey

Propuesta de almacenamiento y procesamiento/validación de datos

Equipo 5

Nombres y Matrículas

Ulises Orlando Carrizalez Lerín	A01027715
Mónica Monserrat Martínez Vásquez	A01710965
María José Soto Castro	A01705840
Tomás Pérez Vera	A01028008
Grant Nathaniel Keegan	A01700753
Bárbara Paola Alcántara Vega	A01799609

TC3006C.101

Inteligencia artificial avanzada para la ciencia de datos II (Gpo 501)

Índice

Introducción.....	3
Contexto del reto.....	3
Herramientas y tecnologías.....	4
Propuestas de almacenamiento.....	4
Propuesta local.....	4
Diagrama de arquitectura.....	5
Propuesta con servidor AWS.....	5
Diagrama de arquitectura.....	6
Diccionario de datos.....	6
Diagrama MER.....	8
Diagrama UML.....	9
Costos y beneficios de la propuesta.....	9
Análisis de enfoque orientado a Big Data.....	9
Ciclo de vida de los datos.....	11
Extracción.....	11
Limpieza.....	11
Transformación.....	11
Integración.....	11
Separación para modelado.....	12
Carga.....	12
NOTA.....	12

Introducción

El presente reto, es un proyecto de ciencia de datos *MuuMetrics*, con el propósito de desarrollar un sistema en minería de datos y análisis de imágenes digitales, para evaluar el *Body Condition Score* (BCS) de las vacas pertenecientes al corral seis del Centro Agro Experimental del Tecnológico de Monterrey (CAETEC).

Haciendo uso de una base de datos de 57,780 imágenes capturadas tras las sesiones de ordeño automático, se plantea el desarrollo de un modelo de aprendizaje profundo, que logre la clasificación del estado corporal de las vacas acorde a una estimación automática de su respectivo BCS, siendo esta una herramienta de apoyo y no de diagnóstico. El alcance del presente proyecto, radica en la mejora de la eficiencia operativa; reducir pérdidas por enfermedades y promover el bienestar animal, sustituyendo la evaluación manual y subjetiva del BCS por un método objetivo y automatizado.

Acorde a la naturaleza del proyecto, se planteó un objetivo de negocio para su desarrollo, el cual es determinar el estado de salud y condición corporal de vacas lecheras del corral seis del CAETEC, del cual se desprende un objetivo de minería de datos, que establece se deben categorizar vacas según su BCS y días en leche (DEL) mediante modelos de aprendizaje automático, donde los principales criterios de éxito radican en obtener una precisión mínima del 80%, y mantener errores estadísticos controlados. Para un mayor entendimiento del presente proyecto, consultar el siguiente documento: [☰ Plan de proyecto](#)

Contexto del reto

El Centro Agropecuario Experimental del Tecnológico de Monterrey (CAETEC), es una instalación de 70 hectáreas orientado a la investigación aplicada en agricultura de precisión y automatización de la producción lechera. El centro cuenta con un sistema de ordeño automático conformado de una serie de robots DeLaval, de tal forma que pueda consolidarse como una “granja de datos”, que permita integrar el análisis científico con la operación agropecuaria.

No obstante, el CAETEC enfrenta retos sanitarios significativos derivado de la ausencia de un sistema automatizado que evalúe individualmente el estado de salud de cada vaca por hato. Actualmente, enfermedades como diarrea, mastitis o lesiones en las ubres, continúan afectando la productividad del centro frecuentemente, así como generando gastos considerables en medicamentos y tratamientos veterinarios. El monitoreo del hato depende aún de la supervisión manual, lo que permite que enfermedades y padecimientos, continúen afectando la productividad del centro frecuentemente, así como generando gastos considerables en medicamentos y tratamientos veterinarios. El monitoreo del hato depende aún de la supervisión manual, lo que retrasa la detección temprana de afecciones, provocando pérdidas por reducción en la producción de leche y aumento en los desechos.

Ante esta situación, surge la necesidad de establecer un método estandarizado que permita la estimación automática del BCS, apoyado en técnicas de visión por computadora y aprendizaje profundo. Con base en este enfoque, se pueden generar diagnósticos más objetivos y consistentes, obteniendo una detección temprana de afecciones y así reducir pérdidas de producto.

Ante esta situación, surge la necesidad de establecer un método estandarizado que permita la estimación automática del BCS , apoyado en técnicas de visión por computadora y aprendizaje profundo. Con base en este enfoque, se pueden generar diagnósticos más objetivos y consistentes, optimizando la atención veterinaria y reduciendo los riesgos asociados a una respuesta tardía. De igual forma, el desarrollo de un sistema replicable adaptativo, fortalecería el papel del CAETEC como referente nacional en tecnificación, salud animal y sostenibilidad en la producción lechera.

Para mayor información del contexto del centro, consultar el siguiente documento: [Background](#)

Herramientas y tecnologías

Para el desarrollo del proyecto *MuuMetrics*, se seleccionó una combinación de librerías, frameworks y servicios orientados a garantizar una manipulación eficiente de los datos, una limpieza automatizada y un flujo reproducible de entrenamiento de modelos. Las herramientas fueron elegidas bajo los criterios de compatibilidad con Python, eficiencia computacional y flexibilidad para el trabajo con datos visuales y tabulares.

<i>Herramienta / Tecnología</i>	<i>Fase(s) de aplicación</i>	<i>Justificación de uso</i>
YOLOv8 (You Only Look Once)	Data preparation	Es adecuado para la orientación de nuestro modelo ya que este modelo pre-entrenado permite recortar regiones de interés (ROI) eliminando ruido de fondo y mejorando la precisión del modelo final de clasificación de BCS al igual que nos permite optimizar la identificación de imágenes que no cuentan con vacas. Además, aísla la región anatómica relevante (lomo, huesos sacros/coccígeos), disminuyendo falsas correlaciones por fondos/variabilidad de encuadre.
OpenCV	Data preparation	Esta herramienta la usamos ya que es una biblioteca central que nos ayuda al procesamiento de imágenes. Es muy útil para la detección de oscuridad, ajuste de brillo, recorte de bordes y conversión de formatos. Permite realizar pre-procesamientos rápidos y reproducibles a nivel píxel. Operaciones rápidas y reproducibles a nivel píxel; permite estandarizar calidad visual antes del modelado.
Roboflow	Data preparation	Esta plataforma se utilizó ya que es muy buena para la aumentación de datos (Aumentación: flip, rotación, blur, ruido, grises). Esto nos permite incrementar la diversidad visual del dataset. Se aplicaron transformaciones como rotación, inversión horizontal, desenfoque y ruido. Ayudándonos a aumentar la diversidad visual dada la escasez de imágenes útiles; ayuda a generalizar el modelo.

PyTorch	Modeling Evaluation	La principal razón del porque este framework fue escogido es por su flexibilidad para tareas como entrenamiento del modelo de aprendizaje profundo. Este modelo es muy importante ya que es el encargado de la clasificación automática de BCS mediante redes neuronales convolucionales (CNN). Es decir, este framework es de las herramientas más importantes ya que se encargará del entrenamiento de la CNN de regresión BCS; métricas MAE, bias, varianza; callback de early stopping, etc. Además de su facilidad de correr modelos y codificarlo.
pandas / NumPy	Data understanding Data preparation Modeling Evaluation	Este conjunto de librerías auxiliares las usamos porque son útiles para la manipulación tabular robusta; cálculo reproducible del match temporal entre fotos y registros. ETL CSVs; cálculo de DEL por imagen; unión y limpieza.
os / shutil	Data Preparation Modeling	Estas dos herramientas son muy útiles ya que nos servirá para la orquestación de carpetas, movimientos seguros (safeMove) en local/nube. Lo cual minimiza errores de E/S y soporta OneDrive/paths en nube.

Propuestas de almacenamiento

Las propuestas de almacenamiento son las siguientes:

Propuesta local

Para mantener un producto y proyecto de acuerdo con los recursos disponibles y fechas límites, se propone mantener el almacenamiento de manera local. Donde solo se almacena el modelo y sus dependencias, mientras que el almacenamiento de imágenes y datos no se haría. Para prevalecer el espacio de almacenamiento de los sistemas locales. Para lograr esto, los datos como CSVs e Imágenes JPG, se guardarán en un aplicación SaaS, en este caso en el espacio de almacenamiento de OneDrive. El usuario podrá consultar los reportes desde su PC utilizando el navegador web de Chrome. Para lograr la conexión con OneDrive se utilizará una conexión con OneDrive API, conectada por medio de protocolo HTTP. Al ingresar el usuario, se pide autenticación dentro del sistema y se hace una petición GET por HTTP a la API.

Diagrama de despliegue




Figura 1. Diagrama de arquitectura local

Como se observa en la figura 1, se muestra el diagrama de usuario de la arquitectura local del sistema, que incluye el modelo de aprendizaje profundo para estimar de forma automática el BCS de las vacas pertenecientes al hato del corral seis del CAETEC.

Como se puede visualizar, el usuario interactúa con el sistema a partir de una PC con sistema operativo Windows 11, utilizando el navegador web Chrome 99 como cliente. A través del protocolo HTTP, el navegador se comunica con un servidor local ejecutado en Node.js, el cual constituye el entorno de ejecución del sistema. De esta manera, el usuario puede consultar imágenes del hato mediante la interfaz web, mientras que el servidor procesa dichas imágenes utilizando el modelo entrenado para estimar el BCS y devuelve los resultados al navegador, completando así el flujo local de interacción entre usuario y sistema.

Para resumir, tenemos que:

1. El usuario accede a la interfaz web desde su PC.
2. El navegador web (Chrome) envía una solicitud HTTP al servidor local.
3. El servidor Node.js recibe la solicitud y valida credenciales y parámetros.
4. El servidor realiza una llamada HTTP a la API de OneDrive para solicitar la imagen o archivo CSV correspondiente.
5. OneDrive responde con la imagen o con una URL firmada de acceso.
6. El servidor procesa la imagen (OpenCV para filtros, YOLOv8 para recorte de ROI).
7. El resultado preprocesado pasa al modelo PyTorch, que estima el BCS.
8. El servidor genera la respuesta (BCS, ID de la vaca, DEL si aplica).
9. El resultado se envía al navegador mediante HTTP, donde el usuario puede visualizarlo.

Propuesta con servidor AWS

Como propuesta escalable a la arquitectura local, se propone utilizar los servicios de AWS (S3, EC2) para crear un sistema más robusto y con almacenamiento de imágenes. Al igual que sea escalable para un flujo de datos mediante cámaras o sensores. El usuario podrá subir manualmente los datos o conectar datos de cámaras y sensores a la arquitectura. Se elimina la dependencia de utilizar OneDrive como forma de almacenamiento. Al guardar datos dentro del sistema, se adaptan los datos dentro del backend del servidor siguiendo el estándar del diccionario de datos propuesto y se almacenan en S3.

Diagrama de despliegue




Figura 2. Diagrama de arquitectura AWS

En la Figura 2 representa el diagrama de usuario de la arquitectura en la nube del sistema de inteligencia artificial diseñado para la estimación automática del BCS (Body Condition Score) de las vacas pertenecientes al hato del corral seis del CAETEC. En esta configuración, el usuario accede al sistema desde una PC con sistema operativo Windows mediante el navegador web Chrome, estableciendo comunicación a través del protocolo HTTP mediante Internet. El servidor se encuentra desplegado en la infraestructura AWS-VPC, utilizando una instancia EC2 con sistema operativo Ubuntu Noble Numbat, donde se ejecuta un entorno Node.js en modo de producción. Además, un proxy reverso NGINX gestiona las peticiones entrantes, optimizando la seguridad y el rendimiento del servidor, mientras que el servicio S3 de AWS se emplea para el almacenamiento de imágenes y resultados. Así, la arquitectura en la nube permite que el usuario interactúe con el sistema desde cualquier ubicación con acceso a Internet, garantizando escalabilidad, disponibilidad y eficiencia en el procesamiento de datos.

Las imágenes procesadas y los resultados generados no se almacenan localmente en el servidor; en su lugar, se guardan y consultan mediante el servicio de almacenamiento AWS S3, permitiendo una gestión eficiente de archivos, reducción de costos y escalabilidad en almacenamiento.

En resumen:

1. El usuario ingresa al sistema desde su PC utilizando un navegador web.
2. El navegador envía una solicitud HTTP/HTTPS al servidor a través de Internet.
3. La solicitud llega a NGINX (Reverse Proxy) en la instancia EC2, quien valida la ruta y la redirige al servicio correspondiente.
4. Node.js recibe la solicitud y determina si requiere acceder a imágenes o procesarlas.
5. Si se requiere una imagen o un archivo, Node.js realiza una solicitud interna a AWS S3 para obtener el recurso.
6. AWS S3 responde con el archivo (o una URL temporal de acceso).
7. Node.js ejecuta el procesamiento de imagen y el modelo de IA para obtener el BCS estimado.
8. El servidor genera una respuesta estructurada que incluye la información analizada y cualquier alerta de salud relevante.
9. La respuesta es entregada nuevamente a través de NGINX, regresando al navegador del usuario, donde se visualiza el resultado.

NGINX no procesa datos, solo gestiona tráfico. Además, Node.js ejecuta la lógica de negocio y el modelo de IA. En cuanto al S3 es el almacenamiento persistente y centralizado. También, la arquitectura está dividida en tres capas:

- Cliente: PC del usuario con navegador.
- Red y Acceso: Internet + NGINX como puerta de entrada controlada.
- Cómputo y Almacenamiento: EC2 ejecutando Node.js y S3 almacenando imágenes y resultados.

Diccionario de datos

<u>cowInfo</u>		
<i>Atributo</i>	<i>Tipo de dato</i>	<i>Descripción</i>
IDCowInfo	int64	Identificador tabla cowInfo
DEL	int64	Días en leche
BCS	real64	Body Score Condition
DateBirth	date	Día de parto, inicio de días en leche.
DateMilking	date	Último día de ordeño
IDCow	int64	No. de identificación de animal

<u>analyticsReport</u>		
<i>Atributo</i>	<i>Tipo de dato</i>	<i>Descripción</i>
IDAnalyticsReport	int64	Identificador tabla analyticsReport
IDCowInfo	int64	Identificador tabla cowInfo
IDImage	int64	Identificador tabla Image
DateHealthStat	date	Día de reporte generado
Status	boolean	La relación BCS y DEL se sale del rango de salud aceptable

<u>Image</u>		
<i>Atributo</i>	<i>Tipo de dato</i>	<i>Descripción</i>
IDImage	int64	Identificador tabla Image
URLImages	String	url de S3

El diccionario de datos define la estructura de las tablas utilizadas en el sistema, especificando los atributos, tipos de datos y su propósito dentro del contexto del análisis de condición corporal (BCS).

Este modelo permite vincular cada imagen procesada con la vaca correspondiente, sus días en leche y el estatus de salud resultante del análisis.

En la tabla cowInfo centralizamos los atributos productivos y fisiológicos relacionados con la vaca para el momento en el que fue capturada la imagen. Permite evaluar el estado corporal y posicionarlo dentro de su curva de lactancia.

La tabla analyticsReport permite generar reportes automáticos que comprueben el estado corporal de la vaca contra los rangos esperados en su etapa productiva. Sirve como base para alertas tempranas.

La tabla Image mantiene la referencia directa a las imágenes originales o recortadas empleadas en el procesamiento para análisis y auditoría.

Diagrama MER




Figura 3. Diagrama de Modelo Entidad Relación

Para el diagrama de modelo entidad relación, los datos son relacionados en el reporte. Por lo que, en el reporte puede haber varias imágenes y varios datos de vacas, pero se genera un solo reporte. En la clase de analyticsReport, solo contiene dos datos. La variable 'DateHealthStat', nos describe la fecha en la que el reporte fue generado, y la variable 'Status' que se deriva de la relación de DEL y BCS. En la entidad de CowInfo, se guarda toda la información importante para la identificación del animal y su evaluación de salud objetivo. Por otro lado, la entidad de Image, solo tiene una variable 'urlImages', que nos permite acceder a la ubicación de las imágenes.

Cuando hablamos de las relaciones y cardinalidades de este modelo de entidad relación, nos dice que una imagen puede ser evaluada varias veces (por ejemplo, con diferentes versiones de modelo).

Además, a lo largo del tiempo, una misma vaca puede generar múltiples reportes de salud. Dándonos así que cada imagen corresponde a una vaca en un momento específico, por lo que se vincula con un único registro de CowInfo.

En el diagrama, estas relaciones aparecen representadas mediante las entidades intermedias Analiza y Diagnostica, que expresan la lógica del negocio:

- Una imagen se analiza para conocer el estado corporal.
- La condición corporal se diagnostica para determinar si es saludable.

Diagrama UML




Figura 4. Diagrama UML

El diagrama UML representa la estructura lógica de las entidades utilizadas en el sistema MuuMetrics y la forma en la que se relacionan para almacenar y consultar información durante el análisis del Body Condition Score (BCS). Cada clase del diagrama corresponde a una tabla en la base de datos, y sus atributos representan los campos que se registran para fines de trazabilidad, procesamiento y consulta.

La clase CowInfo encapsula la información fisiológica asociada a una vaca en el momento en que fue registrada la imagen analizada.

Sus atributos incluyen:

- dateMilking: fecha en la que fue capturada la imagen.
- DEL: días en leche calculados para ese día.
- BCS: Body Condition Score observado o estimado.
- dateBirth: fecha estimada del inicio del ciclo de lactancia.

El atributo IDCow funciona como clave primaria (PK) y permite identificar de manera única cada registro asociado a un evento de análisis de imagen para una vaca.

Ahora, la clase Image almacena únicamente la referencia hacia la imagen utilizada en la evaluación. El archivo no se guarda directamente en la base de datos; en su lugar se almacena:

- UriImage: dirección en el bucket S3 donde se encuentra el archivo.

IDImage es la clave primaria, garantizando la trazabilidad de la imagen utilizada.

En cuanto a la clase analyticsReport, ésta integra la información de una imagen y su contexto fisiológico para producir un reporte de evaluación.

Contiene:

- dateHealthStat: fecha en que se generó la evaluación.
- status: indica si el BCS está dentro o fuera del rango saludable correspondiente a los días en leche.

analyticsReport contiene dos claves foráneas (FK):

- IDCow → Referencia hacia la clase cowInfo
- IDImage → Referencia hacia la clase Image

Cada una de estas tablas se relacionan de distinta manera ya que como podemos ver en la figura 4 una vaca puede tener múltiples reportes a lo largo del tiempo. Así como, una misma imagen puede ser analizada nuevamente con diferentes criterios o modelos.

Costos y beneficios de la propuesta

La propuesta presenta un análisis de costos y beneficios para desarrollar un sistema de estimación automática del Body Condition Score (BCS) en el hato del corral seis del CAETEC, evaluando los recursos necesarios en hardware, procesamiento, almacenamiento y software. Se estima un costo fijo aproximado de 500.5 MXN por tres meses, y los beneficios potenciales incluyen la automatización de la clasificación de imágenes y una mayor eficiencia operativa. Dado su carácter académico, la propuesta se plantea de manera exploratoria, sin garantizar su implementación completa debido a las limitaciones actuales de recursos y tiempo.

Para un mayor entendimiento de los costos y beneficios de esta propuesta puede consultar el siguiente documento:

 [Costos y beneficios de la propuesta](#)

Conclusión de las propuestas de almacenamiento

Durante el desarrollo del proyecto se evaluaron dos alternativas de almacenamiento y despliegue del sistema: una arquitectura local basada en almacenamiento en OneDrive y un servidor local en Node.js, y una arquitectura escalable en la nube mediante AWS (EC2 + S3 + NGINX). Después del análisis técnico, de recursos y de tiempos, se decidió implementar la propuesta local como primera versión funcional del sistema.

Esta decisión se fundamenta en que la solución local se alinea con los tiempos de desarrollo disponibles, requiere menos configuración de infraestructura y permite validar el funcionamiento del pipeline de procesamiento, el modelo de estimación de BCS y la generación de reportes de manera controlada y reproducible.

No obstante, la propuesta con AWS permanece como una propuesta futura, especialmente para escenarios donde se busque operar en tiempo real y con mayor escalabilidad. En una fase futura, integrar cámaras y sensores en la sala de ordeño permitiría capturar automáticamente imágenes de cada vaca al pasar por el robot DeLaval, procesarlas en la nube y estimar el BCS en tiempo real,

almacenando el historial en S3. Esto convertiría al sistema en una herramienta de monitoreo continuo y automatizado.

Por ello, la propuesta local se adopta como versión inicial viable, mientras que la arquitectura AWS se reserva para una fase de escalamiento y automatización completa.

Análisis de enfoque orientado a Big Data

Para poder hacer un análisis informado y correcto del enfoque que se tomará en este proyecto, se consideraron ciertas características estructurales y funcionales con base en la necesidad del socio formador, entre ellas: el volumen de información que se necesita almacenar; la velocidad de acceso requerida; la variedad de datos existentes dentro del contexto del socio formador; que los datos generados por el socio formador sean consistentes y completos; que la naturaleza de los datos provistos por el socio formador, permita la identificación de patrones para realizar inferencias acorde a los requerimientos del socio formador.

<i>Criterio</i>	<i>Situación actual</i>	<i>Evaluación</i>
Volumen	57, 870 imágenes JPG de resolución media 23.5 GB (entre 300 KB a 500 KB cada una) Archivos csv de 1.10MB	El volumen total es de aproximadamente 23.5 GB, lo cual no alcanza el umbral típico de Big Data (que suele superar los terabytes o petabytes). Sin embargo, el tamaño es suficiente para justificar un procesamiento distribuido opcional si se realiza entrenamiento intensivo.
Variedad	Datos homogéneos (imágenes) y variables numéricas (DEL, BCS real)	La variedad parece ser baja a media; los datos son principalmente visuales, sin múltiples fuentes heterogéneas (sensores, audio, texto, etc.)
Velocidad	No existe flujo de datos continuo; el procesamiento es por lotes	No cumple con ese principio de velocidad de Big Data, ya que el análisis no es en tiempo real.
Veracidad	Tanto los datos tabulares como las imágenes proporcionadas por el socio formador no son consistentes ni completas, ya que presentan una serie de atributos con observaciones incompletas o incluso vacías. De igual forma, se dispone de una cantidad considerable de imágenes con ruido, sin la presencia de vacas o con condiciones de iluminación deficientes, lo que dificulta la	Veracidad media, se requiere de limpieza de imágenes vacías, con poca o nula iluminación, borrosas y duplicadas.

	identificación de patrones corporales necesarios para la estimación del índice de condición corporal.	
Valor	Los datos aportan conocimiento significativo sobre la salud y productividad del ganado	Alto valor analítico, aunque el volumen no justifica infraestructura en Big Data

De acuerdo a la tabla anterior, podemos observar que el volumen y complejidad de los datos son moderados.

El sistema actual no requiere arquitectura Big Data, sin embargo sí puede beneficiarse de prácticas escalables, como el uso de almacenamiento en la nube, pipelines ETL bien diseñados y potencial integración futura con sistemas IoT y sensores.

Tras analizar los cinco V de Big Data (Volumen, Variedad, Velocidad, Veracidad y Valor), así como los requisitos técnicos y estratégicos del proyecto MuuMetrics, se concluye que no es necesario implementar un enfoque Big Data en esta etapa.

El tamaño y tipo de datos permiten un tratamiento eficiente mediante minería de datos tradicional y aprendizaje profundo supervisado, utilizando recursos computacionales de nivel medio. Sin embargo, el diseño del sistema debe mantener una arquitectura escalable para una posible segunda fase donde:

- Se integre un flujo en tiempo real de cámaras IoT o sensores DeLaval.
- Se combine información productiva y fisiológica del hato.
- Se requiera almacenamiento distribuido o procesamiento paralelo.

En ese escenario, MuuMetrics podría evolucionar hacia un sistema Big Data Agropecuario, integrando pipelines en tiempo real y análisis predictivo continuo, lo cual abriría nuevas oportunidades de investigación con el CAETEC.

Ciclo de vida de los datos

El ciclo de vida de los datos dentro del proyecto MuuMetrics se estructura conforme al proceso ETL (Extract, Transform, Load) y a la metodología CRISP-DM, abarcando desde la adquisición de los datos proporcionados por el CAETEC hasta su preparación final para el modelado. Este proceso garantiza la calidad, consistencia y confiabilidad de los datos utilizados para el entrenamiento del modelo de estimación automática del BCS.

Extracción

En esta fase, se recopilaban datos provenientes de dos fuentes principales por el CAETEC. Por un lado, se descargaron 57,780 imágenes desde la carpeta *multi* en OneDrive, haciendo uso de sincronización local, dado que por el volumen de datos, la descarga directa por navegador no fue posible. Por otro lado, se descargaron archivos .csv desde la carpeta DATOS VACAS MARZO JUNIO, ubicada en Google Drive, los cuales contenían registros de producción, sanidad y comportamiento del hato del corral seis del CAETEC. Los presentes datos tabulares, fueron generados por el robot DeLaval ubicado en dicho corral durante los procesos de ordeño.

Limpieza y selección

Durante este proceso, se implementaron criterios de calidad para la selección de ambas fuentes de información. Para las imágenes, se desarrolló un sistema de filtrado automático que elimina imágenes con poca iluminación mediante análisis píxeles en escala de grises, seguido de detección de vacas con YOLOv8 para descartar imágenes sin animales visibles, y finalmente una depuración manual que conservó sólo las imágenes con los rasgos anatómicos necesarios para la estimación de BCS. En cuanto a los datos tabulares, se realizó una estandarización de formatos de fecha, eliminación de columnas con información no relevante y concatenación de los 34 archivos individuales por vaca, resultando en un dataset depurado.

Transformación

La transformación de los datos comprendió de múltiples operaciones que ayudaron a enriquecer y preparar los datos para el entrenamiento de datos. Se calculó el valor de Días en Leche (DEL) para cada imagen mediante la diferencia temporal en los archivos .csv y las fechas de captura contenidas en los nombres de cada imagen. Por otro lado, se implementó un etiquetado manual del Body Condition Score, organizando las imágenes en categorías numéricas. Adicionalmente, se aplicaron técnicas de aumentación de datos, incluyendo: rotaciones, flip horizontal, ajuste de brillo y recorte automático con YOLOv8 para focalizar las regiones de interés y reducir ruido de imágenes.

Integración

En la integración se fusionaron sistemáticamente los diferentes conjuntos de datos para crear una base de datos unificada y centralizada. Los 34 archivos .csv individuales, por vaca se combinaron con base en el archivo patadas.csv mediante el identificador único de cada vaca, estableciendo relaciones cruzadas que posibilitaron asociar cada imagen con sus respectivos registros de producción y días en leche. Esta vinculación temporal posibilitó la creación de un único dataset consolidado con las columnas clave: ID, Fecha, DEL y BCS, integrando con coherencia la información visual con los datos zootécnicos para el análisis posterior y modelado.

Separación para modelado

La separación para modelado implementó una estrategia de división que garantiza equilibrio entre las clases de CBS en los conjuntos de entrenamiento (70%), validación (15%) y prueba (15%). Deliberadamente los datos sintéticos generados por aumentación de datos, fueron excluidos de los conjuntos de validación y prueba para asegurar que las métricas de evaluación reflejen el rendimiento real del modelo sobre datos originales.

Carga y almacenamiento

La fase de carga y almacenamiento organizó todos los datos procesados, scripts y modelos en un repositorio que pueda facilitar la reproducibilidad y trazabilidad del proceso. Se establecieron directorios específicos para cada componente del proyecto, incluyendo códigos en Python, modelos YOLO v8 y documentación asociada. El dataset final, compuesto por 628 imágenes etiquetadas, queda disponible para el entrenamiento de modelos de visión por computadora orientados a la estimación automática del BCS.

Script	Descripción
calculoDELvacas.py	Calcula los Días en Leche (DEL) por imagen mediante integración de registros de ordeño y fechas de captura, fusionando 34 archivos CSV individuales.
limpiarVacas.py	Filtra y depura imágenes mediante detección de oscuridad, identificación de vacas con YOLOv8, y aplicación de brillo.
CropCow.py	Recorta automáticamente las regiones de interés en imágenes usando un modelo YOLOv8 entrenado, eliminando ruido de fondo.
dataAugmentation.py	Aplicar técnicas de aumentación de datos para expandir el dataset de entrenamiento.
GenYoloModel.py	Genera y entrena modelos personalizados de detección de objetos basados en YOLOv8 para identificación de vacas.
MuClassifier.py	Aplicación local para etiquetado manual de Body Condition Score en imágenes, organizado por categorías.

NOTA

Todo el detalle técnico, scripts utilizados y evidencias del proceso ETL se documentan ampliamente en el Reporte de data preparation, disponible en el siguiente link:

 [Reporte de preparación de datos](#)

Conclusión

El presente reporte documenta la propuesta de almacenamiento y procesamiento de datos para el sistema de estimación automática del BCS dentro del proyecto MuuMetrics. Se describieron las herramientas y tecnologías empleadas durante la preparación de datos y las distintas fases de la metodología CRISP-DM para asegurar un flujo de trabajo reproducible, escalable y estructurado.

Asimismo, se presentaron dos alternativas de arquitectura para la gestión de los datos: una solución local utilizando OneDrive y un servidor Node.js, y una solución escalable basada en servicios de AWS. Tras el análisis de costos, tiempos de desarrollo y alcance del presente periodo, se concluyó que la arquitectura local es la opción más adecuada para la primera versión del sistema, al permitir la ejecución y validación del modelo de manera ágil. Sin embargo, la arquitectura en AWS permanece como la opción recomendada para una fase futura donde se busque automatizar la toma de imágenes con sensores y cámaras en tiempo real, permitiendo diagnósticos continuos dentro del hato.

En cuanto al ciclo de vida de los datos, se lograron los siguientes resultados:

- Extracción: Se consolidaron 57,780 imágenes y archivos .csv provenientes del sistema DeLaval.

- Limpieza: Se eliminaron imágenes sin vacas, con baja iluminación o duplicadas y se estandarizaron los registros tabulares.
- Transformación: Se calcularon los Días en Leche (DEL), se etiquetó el BCS y se aplicó aumentación para mejorar la variabilidad visual.
- Integración: Se fusionaron imágenes y datos fisiológicos para generar un dataset final consistente.
- Separación y carga: Se estructuró el dataset final en conjuntos de entrenamiento, validación y prueba, y se organizó el repositorio de scripts y modelos para asegurar trazabilidad.

Finalmente, se definió el diccionario de datos, y se establecieron los diagramas MER y UML que modelan la relación entre imágenes, atributos productivos y reportes generados, proporcionando una estructura clara y coherente para el almacenamiento de información.

En conjunto, este reporte consolida una base sólida para la implementación del sistema de estimación automática del BCS, dejando preparado el camino para su escalamiento, incorporación de captura automatizada y futura integración en tiempo real dentro del entorno operativo del CAETEC.