



Tecnológico de Monterrey

Propuesta de almacenamiento y procesamiento de datos

Equipo 5

Nombres y Matrículas

Ulises Orlando Carrizalez Lerín	A01027715
Mónica Monserrat Martínez Vásquez	A01710965
María José Soto Castro	A01705840
Tomás Pérez Vera	A01028008
Grant Nathaniel Keegan	A01700753
Bárbara Paola Alcántara Vega	A01799609

TC3006C.101

Inteligencia artificial avanzada para la ciencia de datos II (Gpo 501)

Índice

Introducción.....	3
Contexto del reto.....	3
Herramientas y tecnologías.....	4
Propuestas de almacenamiento.....	4
Propuesta local.....	4
Diagrama de arquitectura.....	5
Propuesta con servidor AWS.....	5
Diagrama de arquitectura.....	6
Diccionario de datos.....	6
Diagrama MER.....	7
Diagrama UML.....	8
Costos y beneficios de la propuesta.....	8
Análisis de enfoque orientado a Big Data.....	8
Ciclo de vida de los datos.....	10
Extracción.....	10
Limpieza.....	10
Transformación.....	10
Integración.....	10
Separación para modelado.....	11
Carga.....	11
NOTA.....	11

Introducción

El presente reto, es un proyecto de ciencia de datos *MuuMetrics*, con el propósito de desarrollar un sistema en minería de datos y análisis de imágenes digitales, para evaluar el *Body Condition Score* (BCS) de las vacas pertenecientes al corral seis del Centro Agro Experimental del Tecnológico de Monterrey (CAETEC).

Haciendo uso de una base de datos de 57,780 imágenes capturadas tras las sesiones de ordeño automático, se plantea el desarrollo de un modelo de aprendizaje profundo, que logre la clasificación del estado corporal de las vacas acorde a una estimación automática de su respectivo BCS, siendo esta una herramienta de apoyo y no de diagnóstico. El alcance del presente proyecto, radica en la mejora de la eficiencia operativa; reducir pérdidas por enfermedades y promover el bienestar animal, sustituyendo la evaluación manual y subjetiva del BCS por un método objetivo y automatizado.

Acorde a la naturaleza del proyecto, se planteó un objetivo de negocio para su desarrollo, el cual es determinar el estado de salud y condición corporal de vacas lecheras del corral seis del CAETEC, del cual se desprende un objetivo de minería de datos, que establece se deben categorizar vacas según su BCS y días en leche (DEL) mediante modelos de aprendizaje automático, donde los principales criterios de éxito radican en obtener una precisión mínima del 80%, y mantener errores estadísticos controlados. Para un mayor entendimiento del presente proyecto, consultar el siguiente documento: [☰ Plan de proyecto](#)

Contexto del reto

El Centro Agropecuario Experimental del Tecnológico de Monterrey (CAETEC), es una instalación de 70 hectáreas orientado a la investigación aplicada en agricultura de precisión y automatización de la producción lechera. El centro cuenta con un sistema de ordeño automático conformado de una serie de robots DeLaval, de tal forma que pueda consolidarse como una “granja de datos”, que permita integrar el análisis científico con la operación agropecuaria.

No obstante, el CAETEC enfrenta retos sanitarios significativos derivado de la ausencia de un sistema automatizado que evalúe individualmente el estado de salud de cada vaca por hato. Actualmente, enfermedades como diarrea, mastitis o lesiones en las ubres, continúan afectando la productividad del centro frecuentemente, así como generando gastos considerables en medicamentos y tratamientos veterinarios. El monitoreo del hato depende aún de la supervisión manual, lo que permite que enfermedades y padecimientos, continúen afectando la productividad del centro frecuentemente, así como generando gastos considerables en medicamentos y tratamientos veterinarios. El monitoreo del hato depende aún de la supervisión manual, lo que retrasa la detección temprana de afecciones, provocando pérdidas por reducción en la producción de leche y aumento en los desechos.

Ante esta situación, surge la necesidad de establecer un método estandarizado que permita la estimación automática del BCS, apoyado en técnicas de visión por computadora y aprendizaje profundo. Con base en este enfoque, se pueden generar diagnósticos más objetivos y consistentes, obteniendo una detección temprana de afecciones y así reducir pérdidas de producto.

Ante esta situación, surge la necesidad de establecer un método estandarizado que permita la estimación automática del BCS , apoyado en técnicas de visión por computadora y aprendizaje profundo. Con base en este enfoque, se pueden generar diagnósticos más objetivos y consistentes, optimizando la atención veterinaria y reduciendo los riesgos asociados a una respuesta tardía. De igual forma, el desarrollo de un sistema replicable adaptativo, fortalecería el papel del CAETEC como referente nacional en tecnificación, salud animal y sostenibilidad en la producción lechera.

Para mayor información del contexto del centro, consultar el siguiente documento: [Background](#)

Herramientas y tecnologías

Para el desarrollo del proyecto MuuMetrics, se seleccionó una combinación de librerías, frameworks y servicios orientados a garantizar una manipulación eficiente de los datos, una limpieza automatizada y un flujo reproducible de entrenamiento de modelos. Las herramientas fueron elegidas bajo los criterios de compatibilidad con Python, eficiencia computacional y flexibilidad para el trabajo con datos visuales y tabulares.

- YOLOv8 (You Only Look Once)
- OpenCV
- Roboflow
- os / shutil / pandas / NumPy
- TensorFlow

Para más detalles de descripción y justificación de uso, consultar el siguiente documento en el apartado de herramientas y tecnologías:

[Reporte inicial de descripción, calidad y exploración de datos](#)


Propuestas de almacenamiento

Las propuestas de almacenamiento son las siguientes:

Propuesta local

Para mantener un producto y proyecto de acuerdo con los recursos disponibles y fechas límites, se propone mantener el almacenamiento de manera local. Donde solo se almacena el modelo y sus dependencias, mientras que el almacenamiento de imágenes y datos no se haría. Para prevalecer el espacio de almacenamiento de los sistemas locales.


Diagrama de arquitectura



Propuesta con servidor AWS

Como propuesta escalable a la arquitectura local, se propone utilizar los servicios de AWS (S3, EC2) para crear un sistema más robusto y con almacenamiento de imágenes. Al igual que sea escalable para un flujo de datos mediante cámaras o sensores.

Diagrama de arquitectura



Diccionario de datos

<u>cowInfo</u>		
<i>Atributo</i>	<i>Tipo de dato</i>	<i>Descripción</i>
IDCowInfo	int64	Identificador tabla cowInfo
DEL	int64	Días en leche
BCS	real64	Body Score Condition
DateBirth	date	Día de parto, inicio de días en leche.
DateMilking	date	Último día de ordeño
IDCow	int64	No. de identificación de animal

<u>analyticsReport</u>		
<i>Atributo</i>	<i>Tipo de dato</i>	<i>Descripción</i>
IDAnalyticsReport	int64	Identificador tabla analyticsReport
IDCowInfo	int64	Identificador tabla cowInfo

IDImage	int64	Identificador tabla Image
DateHealthStat	date	Día de reporte generado
Status	boolean	La relación BCS y DEL se sale del rango de salud aceptable

<i>Image</i>		
<i>Atributo</i>	<i>Tipo de dato</i>	<i>Descripción</i>
IDImage	int64	Identificador tabla Image
URLImages	String	url de S3

Diagrama MER





Diagrama UML



Costos y beneficios de la propuesta

La propuesta presenta un análisis de costos y beneficios para desarrollar un sistema de estimación automática del Body Condition Score (BCS) en el hato del corral seis del CAETEC, evaluando los recursos necesarios en hardware, procesamiento, almacenamiento y software. Se estima un costo fijo aproximado de 500.5 MXN por tres meses, y los beneficios potenciales incluyen la automatización de la clasificación de imágenes y una mayor eficiencia operativa. Dado su carácter académico, la propuesta se plantea de manera exploratoria, sin garantizar su implementación completa debido a las limitaciones actuales de recursos y tiempo.

Para un mayor entendimiento de los costos y beneficios de esta propuesta puede consultar el siguiente documento:

[Costos y beneficios de la propuesta](#)

Análisis de enfoque orientado a Big Data

Para poder hacer un análisis informado y correcto del enfoque que se tomará en este proyecto, se consideraron ciertas características estructurales y funcionales con base en la necesidad del socio formador, entre ellas: el volumen de información que se necesita almacenar; la velocidad de acceso requerida; la variedad de datos existentes dentro del contexto del socio formador; que los datos generados por el socio formador sean consistentes y completos; que la naturaleza de los datos provistos por el socio formador, permita la identificación de patrones para realizar inferencias acorde a los requerimientos del socio formador.

<i>Criterio</i>	<i>Situación actual</i>	<i>Evaluación</i>
Volumen	57, 870 imágenes JPG de resolución media 23.5 GB (entre 300 KB a 500 KB cada una) Archivos csv de 1.10MB	El volumen total es de aproximadamente 23.5 GB, lo cual no alcanza el umbral típico de Big Data (que suele superar los terabytes o petabytes). Sin embargo, el tamaño es suficiente para justificar un procesamiento distribuido opcional si se realiza entrenamiento intensivo.
Variedad	Datos homogéneos (imágenes) y variables numéricas (DEL, BCS real)	La variedad parece ser baja a media; los datos son principalmente visuales, sin múltiples fuentes heterogéneas (sensores, audio, texto, etc.)
Velocidad	No existe flujo de datos continuo; el procesamiento es por lotes	No cumple con ese principio de velocidad de Big Data, ya que el análisis no es en tiempo real.
Veracidad	Tanto los datos tabulares como las imágenes proporcionadas por el socio formador no son consistentes ni completas, ya que presentan una serie de atributos con observaciones incompletas o incluso vacías. De igual forma, se dispone de una cantidad considerable de imágenes con ruido, sin la presencia de vacas o con condiciones de iluminación deficientes, lo que dificulta la identificación de patrones corporales necesarios para la estimación del índice de condición corporal.	Veracidad media, se requiere de limpieza de imágenes vacías, con poca o nula iluminación, borrosas y duplicadas.
Valor	Los datos aportan conocimiento significativo sobre la salud y productividad del ganado	Alto valor analítico, aunque el volumen no justifica infraestructura en Big Data

De acuerdo a la tabla anterior, podemos observar que el volumen y complejidad de los datos son moderados.

El sistema actual no requiere arquitectura Big Data, sin embargo sí puede beneficiarse de prácticas escalables, como el uso de almacenamiento en la nube, pipelines ETL bien diseñados y potencial integración futura con sistemas IoT y sensores.

Tras analizar los cinco V de Big Data (Volumen, Variedad, Velocidad, Veracidad y Valor), así como los requisitos técnicos y estratégicos del proyecto MuuMetrics, se concluye que no es necesario implementar un enfoque Big Data en esta etapa.

El tamaño y tipo de datos permiten un tratamiento eficiente mediante minería de datos tradicional y aprendizaje profundo supervisado, utilizando recursos computacionales de nivel medio. Sin embargo, el diseño del sistema debe mantener una arquitectura escalable para una posible segunda fase donde:

- Se integre un flujo en tiempo real de cámaras IoT o sensores DeLaval.
- Se combine información productiva y fisiológica del hato.
- Se requiera almacenamiento distribuido o procesamiento paralelo.

En ese escenario, MuuMetrics podría evolucionar hacia un sistema Big Data Agropecuario, integrando pipelines en tiempo real y análisis predictivo continuo, lo cual abriría nuevas oportunidades de investigación con el CAETEC.

Ciclo de vida de los datos

El ciclo de vida de los datos dentro del proyecto MuuMetrics se estructura conforme al proceso ETL (Extract, Transform, Load) y a la metodología CRISP-DM, abarcando desde la adquisición de los datos proporcionados por el CAETEC hasta su preparación final para el modelado.

A grandes rasgos, este ciclo comprende las siguientes fases:

Extracción

Descarga de imágenes y archivos **.csv** desde las fuentes oficiales del CAETEC (OneDrive y Drive compartido).

- Las imágenes fueron descargadas desde OneDrive del proyecto (multi folder) mediante sincronización local.
- Los archivos .csv se extrajeron desde la carpeta “DATOS VACAS MARZO JUNIO” del Drive compartido.

Limpieza

Depuración de imágenes oscuras o sin vacas, eliminación de columnas irrelevantes y estandarización de nombres y formatos.

Transformación

Cálculo de Días en Leche(DEL) por imagen, etiquetado del Body Condition Score (BCS), y aumentación de datos mediante rotaciones, ruido y reflejos horizontales.

Integración

Fusión de los 34 archivos individuales por vaca con el archivo patadas.csv, obteniendo un único dataset consolidado con las columnas clave: ID, Fecha, DEL y BCS.

Separación para modelado

División del dataset en conjuntos de entrenamiento, validación y prueba bajo el esquema k-fold cross validation, garantizando equilibrio entre clases y reducción del sobreajuste. Además de incluir un aumento de datos para mejorar la precisión del modelo.

Carga

Almacenamiento local de los datos depurados y carga de los scripts y muestras al repositorio oficial del proyecto, para asegurar reproducibilidad y trazabilidad.

NOTA

Todo el detalle técnico, scripts utilizados y evidencias del proceso ETL se documentan ampliamente en el Reporte de data preparation, disponible en el siguiente link:

 [Reporte de data preparation](#)